دانشگاه صنعتی شریف

دانشکده مهندسی صنایع

گزارش جامع پروژه نهایی درس

مبانی داده‌کاوی و کاربرده ای آن

دکتر مریم بستان‌آرا

پیش‌بینی وضعیت تأیید درخواست وام

با استفاده از روش‌های داده‌کاوی، یادگیری ماشین و تفسیرپذیری مدل

گروه ۱:

سونیا دباغ تفرشی ۴۰۱۱۰۴۱۰۲

پردیس رحیمی نصر ۴۰۱۱۷۰۴۰۱

تیر ۱۴۰۵

فهرست مطالب

فهرست جداول ۳
فهرست اشکال ۴
جدول تقسیم وظایف ۵
چکیده ۶
۱. مقدمه ۷
۱-۱. تعریف مسئله و اهمیت آن ۷
۱-۲. هدف و پرسش‌های پروژه ۷
۱-۳. مرور مختصر ادبیات ۷
۱-۴. دامنه و محدودیت اولیه ۸
۱-۵. ساختار گزارش ۸
۲. داده و پیش‌پردازش ۹
۲-۱. منبع و ساختار داده ۹
۲-۲. جریان کلی تحلیل ۹
۲-۳. بررسی کیفیت داده و قواعد دامنه ۹
۲-۴. آمار توصیفی ۱۰
۲-۵. مقادیر گمشده و توزیع هدف ۱۰
۲-۶. تحلیل اکتشافی روابط با متغیر هدف ۱۱
۲-۷. توزیع، چولگی و داده‌های پرت ۱۳
۲-۸. همبستگی متغیرهای عددی ۱۴
۲-۹. تقسیم داده و جلوگیری از نشت اطلاعات ۱۴
۲-۱۰. مهندسی ویژگی ۱۵
۲-۱۱. مقایسه روش‌های پیش‌پردازش ۱۵
۲-۱۱-۱. جای‌گذاری مقادیر گمشده ۱۵
۲-۱۱-۲. مقیاس‌بندی ۱۶
۲-۱۱-۳. مدیریت چولگی و داده‌های پرت ۱۶
۲-۱۱-۴. مدیریت عدم تعادل کلاس ۱۷
۲-۱۲. پایپ‌لاین نهایی پیش‌پردازش ۱۷
۳. مدل‌سازی، ارزیابی و نتایج ۱۹
۳-۱. مدل‌های بررسی‌شده ۱۹

۳-۲. تنظیمات آزمایش و اعتبارسنجی ۱۹
۳-۴. معیارهای ارزیابی ۲۰
۳-۵. عملکرد مدل‌های مبنا ۲۱
۳-۶. نتایج تنظیم ابرپارامتر ۲۱
۳-۷. اثر تنظیم ابرپارامتر ۲۲
۳-۸. تحلیل پایداری و انتخاب مدل نهایی ۲۲
۳-۹. ارزیابی مدل منتخب روی مجموعه نگه‌داشته‌شده ۲۳
۳-۱۰. منحنی‌های ROC و دقت ـ فراخوانی ۲۴
۳-۱۱. تنظیم آستانه تصمیم ۲۵
۳-۱۲. تحلیل خطاها ۲۶
۳-۱۳. اهمیت ویژگی‌ها با روش جایگشتی ۲۷
۳-۱۴. تفسیر جهانی با SHAP ۲۷
۳-۱۵. تفسیر محلی تصمیم‌ها ۲۸
۳-۱۶. توضیح محلی LIME-style ۲۹
۳-۱۷. وابستگی جزئی ۳۰
۳-۱۸. منحنی یادگیری و بیش‌برازش ۳۰
۳-۱۹. تحلیل عملکرد در زیرگروه‌ها ۳۱
۳-۲۰. بحث و برداشت از نتایج ۳۲
۳-۲۱. آموزش نهایی و پیش‌بینی داده آزمون ۳۲
۴. نتیجه‌گیری ۳۲
۵. فهرست مراجع ۳۵

فهرست جداول

جدول ۱. تقسیم وظایف فنی و نگارشی اعضای گروه ۵
جدول ۲ .تعریف متغیرهای مورد استفاده در پروژه ۹
جدول ۳. نتیجه بررسی کیفیت داده خام ۱۰
جدول ۴. آمار توصیفی متغیرهای عددی پس از اعمال قواعد دامنه ۱۰
جدول ۵. مقادیر گمشده در داده آموزش ۱۰
جدول ۶. شناسایی داده‌های پرت با قاعده IQR ۱۳
جدول ۷. مقایسه روش‌های جای‌گذاری ۱۵
جدول ۸. مقایسه روش‌های مقیاس‌بندی ۱۶
جدول ۹. مقایسه سناریوهای مدیریت چولگی و داده پرت ۱۷
جدول ۱۰. مقایسه روش‌های مدیریت عدم تعادل ۱۷
جدول ۱۱. تصمیم نهایی اجزای پیش‌پردازش ۱۷
جدول ۱۲. فضای تنظیم ابرپارامتر مدل‌ها ۱۹
جدول ۱۳. نتایج مدل‌های مبنا پیش از تنظیم ابرپارامتر ۲۱
جدول ۱۴. مقایسه مدل‌های تنظیم‌شده روی مجموعه نگه‌داشته‌شده ۲۲
جدول ۱۵. تغییر عملکرد پیش و پس از تنظیم ۲۲
جدول ۱۶. تحلیل پایداری مدل‌های برتر ۲۳
جدول ۱۷. مقایسه اجزای ماتریس درهم‌ریختگی مدل‌های تنظیم‌شده ۲۴
جدول ۱۸. مهم‌ترین ویژگی‌ها بر پایه میانگین قدر مطلق SHAP ۲۷
جدول ۱۹ .توضیحات محلی LIME-style ۳۰
جدول ۲۰. عملکرد مدل در زیرگروه‌های دارای حداقل ۱۰ نمونه ۳۱

فهرست اشکال

شکل ۱. جریان کلی پروژه از داده خام تا پیش‌بینی نهایی ۹
شکل ۲. کیفیت داده و عدم تعادل نسبی کلاس‌ها ۱۱
شکل ۳. نرخ تأیید بر اساس جنسیت ۱۱
شکل ۴. نرخ تأیید بر اساس وضعیت تأهل ۱۱
شکل ۵. نرخ تأیید بر اساس تحصیلات ۱۲
شکل ۶. نرخ تأیید بر اساس محل سکونت ۱۲
شکل ۷. نرخ تأیید بر اساس سابقه اعتباری ۱۲
شکل ۸ .توزیع دو متغیر مالی منتخب ۱۳
شکل ۹. ماتریس همبستگی متغیرهای عددی و متغیر هدف ۱۴
شکل ۱۰. ماتریس درهم‌ریختگی SVM ۲۳
شکل ۱۱. مقایسه مدل‌های تنظیم‌شده ۲۵
شکل ۱۲. تحلیل آستانه با پیش‌بینی‌های خارج از نمونه ۲۶
شکل ۱۳. ماتریس درهم‌ریختگی پس از تغییر آستانه ۲۶
شکل ۱۴. اهمیت جایگشتی ویژگی‌های خام بر پایه کاهش F1 ..... ۲۷
شکل ۱۵. تفسیر جهانی مدل منتخب با SHAP ۲۸
شکل ۱۶. دو توضیح محلی SHAP ۲۹
شکل ۱۷ LIME ۳۰
شکل ۱۸. نمودار وابستگی جزئی ویژگی‌های منتخب در مدل SVM ۳۰
شکل ۱۹. منحنی یادگیری مدل منتخب بر پایه F1 ..... ۳۱

جدول تقسیم وظایف

تقسیم کار بر مبنای ترتیب محتوایی نوت‌بوک انجام شده است: بخش‌های ۱ تا ۶ بر عهده سونیا دباغ تفرشی و بخش‌های ۷ تا ۱۳ بر عهده پردیس رحیمی نصر بوده است. نگارش گزارش نیز متناسب با همین مرز محتوایی و به‌صورت برابر تقسیم شده است. جدول ۱ مسئول انجام هر فعالیت را از کل پروژه نشان می‌دهد.

جدول ۱. تقسیم وظایف فنی و نگارشی اعضای گروه

فعالیت	مسئول
آماده‌سازی محیط، بارگذاری فایل‌ها، کنترل مسیرها و ساختار اولیه داده	سونیا دباغ تفرشی
ممیزی کیفیت داده، قواعد دامنه، آمار توصیفی و بررسی مقادیر گمشده	
تحلیل اکتشافی، نرخ‌های تأیید، توزیع‌ها، داده‌های پرت و همبستگی	
تقسیم داده، طراحی پایپ‌لاین بدون نشت اطلاعات و مهندسی ویژگی	
مقایسه روش‌های جای‌گذاری، مقیاس‌بندی، مدیریت چولگی و عدم تعادل	
نگارش مقدمه، مرور مختصر ادبیات و تعریف مسئله و پرسش‌ها	
نگارش بخش داده، تحلیل اکتشافی و پیش‌پردازش و آماده‌سازی جداول آن	
بازبینی نیمه نخست گزارش و آماده‌سازی شکل‌های مرتبط با داده	
پیاده‌سازی و ارزیابی شش مدل مبنا	
تعریف فضای جست‌وجو، تنظیم ابرپارامتر و اعتبارسنجی متقابل	پردیس رحیمی نصر
تحلیل پایداری، انتخاب مدل و مقایسه قبل و بعد از تنظیم	
ارزیابی نهایی، ماتریس درهم‌ریختگی، منحنی‌های ROC و PR و تنظیم آستانه	
تحلیل خطاهای FP/FN و بررسی عملکرد در زیرگروه‌ها	
تفسیرپذیری با Permutation Importance، SHAP، LIME-style و PDP	
منحنی یادگیری، آموزش نهایی و تولید پیش‌بینی برای داده آزمون	
نگارش روش مدل‌سازی، تنظیمات آزمایش و معیارهای ارزیابی	
نگارش نتایج، تحلیل خطا، تفسیرپذیری، بحث و بینش‌های کاربردی	
نگارش نتیجه‌گیری، تنظیم مراجع و بازبینی نهایی نیمه دوم گزارش	

چکیده

در این پروژه هدف ما پیش‌بینی تأیید یا رد درخواست وام با استفاده از اطلاعات جمعیت‌شناختی، درآمدی، اعتباری و مشخصات وام بود. داده‌ی آموزش شامل ۶۱۴ درخواست برچسب‌دار و ۱۱ ویژگی و داده‌ی آزمون شامل ۳۶۷ درخواست بدون برچسب بود. ابتدا کیفیت داده بررسی شد و مقادیر نامعتبر مبلغ وام به‌صورت مقدار گمشده در نظر گرفته شدند. سپس توزیع متغیرها، مقادیر گمشده، داده‌های پرت، همبستگی‌ها و وضعیت تعادل کلاس‌ها تحلیل شد. برای اینکه انتخاب مراحل پیش‌پردازش سلیقه‌ای نباشد، چند روش جای‌گذاری، مقیاس‌بندی، مدیریت چولگی و متعادل‌سازی با اعتبارسنجی متقابل مقایسه شدند. روش نهایی شامل جای‌گذاری میانگین برای متغیرهای عددی، جای‌گذاری مقدار پرتکرار برای متغیرهای دسته‌ای، مقیاس‌بندی حداقل حداکثر، تبدیل لگاریتمی و عدم نمونه‌برداری بود. شش مدل رگرسیون لجستیک، نزدیک‌ترین همسایه، ماشین بردار پشتیبان، درخت تصمیم، جنگل تصادفی و گرادیان بوستینگ اجرا و ابرپارامترهای آن‌ها تنظیم شد. در اعتبارسنجی متقابل تکرارشونده، ماشین بردار پشتیبان در اعتبارسنجی متقاطع تکرارشونده، با میانگین معیار F1 برابر با ۰/۸۷۰۷، بالاترین میانگین F1 را در میان مدل‌های مقایسه‌شده به دست آورد؛ هرچند اختلاف آن با برخی مدل‌های رقیب بسیار محدود بود. این مدل روی مجموعه‌ی نگه‌داشته‌شده به دقت ۰/۸۵۳۷، فراخوانی ۰/۹۸۸۲ برای کلاس تأیید وام و F1 برابر با ۰/۹۰۳۲ دست یافت. نتایج تحلیل اهمیت جایگشتی و SHAP نیز نشان دادند که متغیر سابقه‌ی اعتباری، مهم‌ترین ویژگی مورد استفاده مدل برای پیش‌بینی وضعیت درخواست وام بوده است. بااین‌حال، عملکرد مدل در شناسایی درخواست‌های ردشده ضعیف‌تر بود و باید در تفسیر عملکرد نهایی آن مورد توجه قرار گیرد. در پایان برای هر ۳۶۷ نمونه آزمون، برچسب و احتمال تأیید تولید و ذخیره شد.

واژگان کلیدی: پیش‌بینی تأیید وام، داده‌کاوی، یادگیری ماشین، ماشین بردار پشتیبان، عدم تعادل کلاس، تفسیرپذیری، SHAP

۱. مقدمه

۱-۱. تعریف مسئله و اهمیت آن

تصمیم‌گیری درباره اعطای وام یکی از مهم‌ترین فرایندهای مؤسسات مالی و بانک‌ها به شمار می‌رود. اگر درخواست متقاضیان واجد شرایط به اشتباه رد شود، علاوه بر از دست رفتن مشتریان، درآمد مؤسسه نیز کاهش می‌یابد. از سوی دیگر، تأیید درخواست متقاضیان پرریسک می‌تواند منجر به افزایش ریسک اعتباری و تحمیل زیان‌های مالی شود. به همین دلیل، استفاده از روش‌های دقیق برای ارزیابی متقاضیان اهمیت زیادی دارد. امتیازدهی اعتباری[۱] مجموعه‌ای از روش‌های آماری و محاسباتی است که با تحلیل ویژگی‌های متقاضیان، آن‌ها را از نظر احتمال بازپرداخت وام و میزان ریسک اعتباری طبقه‌بندی می‌کند و به مؤسسات مالی در اتخاذ تصمیم‌های آگاهانه‌تر کمک می‌کند. [۱]

یادگیری ماشین این امکان را می‌دهد که علاوه بر روابط خطی، الگوهای غیرخطی و تعامل بین ویژگی‌ها نیز بررسی شوند. نتایج مطالعات مقایسه‌ای نشان داده‌اند که هیچ الگوریتمی در همه‌ی مجموعه‌داده‌های اعتباری بهترین نیست و کیفیت نتیجه به نوع داده، روش پیش‌پردازش، معیار انتخاب و نحوه‌ی اعتبارسنجی بستگی دارد. [۲] به همین دلیل در این پروژه فقط به اجرای یک مدل اکتفا نکردیم و چند روش پیش‌پردازش، شش الگوریتم، تنظیم ابرپارامتر و چند روش تفسیرپذیری را کنار هم مقایسه کردیم.

۱-۲. هدف و پرسش‌های پروژه

هدف اصلی ما ساخت یک روند قابل تکرار برای پیش‌بینی وضعیت درخواست وام و رسیدن به نتیجه‌ای بود که فقط به یک عدد دقت محدود نشود. پرسش‌های اصلی پروژه عبارت‌اند از:

۱. کدام ویژگی‌ها بیشترین ارتباط را با وضعیت تأیید درخواست دارند؟

۲. کدام روش جای‌گذاری، مقیاس‌بندی و مدیریت چولگی برای این داده مناسب‌تر است؟

۳. آیا روش‌های نمونه‌برداری یا وزن‌دهی کلاس، عملکرد را بهبود می‌دهند؟

۴. تنظیم ابرپارامترها چه اثری بر عملکرد شش الگوریتم منتخب دارد؟

۵. کدام مدل از نظر پایداری اعتبارسنجی متقابل مناسب‌تر است؟

۶. خطاهای مثبت و منفی مدل چه الگوهایی دارند؟

۷. روش‌های تفسیرپذیری چه تصویری از عوامل مؤثر بر تصمیم مدل ارائه می‌کنند؟

۱-۳. مرور مختصر ادبیات

روش‌های کلاسیک امتیازدهی اعتباری از مدل‌های آماری مانند رگرسیون لجستیک و تحلیل ممیزی آغاز شده‌اند، اما به‌تدریج روش‌های یادگیری ماشین نیز وارد این حوزه شده‌اند. [۱] هوانگ و همکاران نشان دادند که ماشین بردار پشتیبان می‌تواند در مسائل امتیازدهی اعتباری عملکرد رقابتی داشته باشد و انتخاب ویژگی

---

[۱] Credit scoring

و تنظیم پارامترها در نتیجه مؤثر است. [۳] خاندانی و همکاران نیز نشان دادند که الگوریتم‌های یادگیری ماشین می‌توانند الگوهای پیش‌بینی ریسک اعتباری را از داده‌های مصرف‌کننده استخراج کنند. [۴]

مطالعه‌ی بنچمارک لسمان و همکاران، ۴۱ طبقه‌بند را روی چند مجموعه‌داده اعتباری بررسی کرد و بر اهمیت مقایسه چندمعیاره و ارزیابی مالی تأکید داشت. [۲] در میان الگوریتم‌های این پروژه، ماشین بردار پشتیبان بر اصل بیشینه‌سازی حاشیه استوار است [۵]، جنگل تصادفی از تجمیع درخت‌های تصادفی استفاده می‌کند [۶] و گرادیان بوستینگ با افزودن تدریجی یادگیرنده‌های ضعیف، خطای تابع هدف را کاهش می‌دهد [۷]. برای عدم تعادل کلاس نیز روش SMOTE یکی از روش‌های شناخته‌شده تولید نمونه مصنوعی است. [۸]

در کاربردهای حساس، دقت پیش‌بینی به‌تنهایی کافی نیست و باید منطق تصمیم مدل نیز بررسی شود. روش SHAP سهم ویژگی‌ها را بر پایه مقادیر شاپلی بیان می‌کند و LIME با برازش یک مدل ساده در همسایگی نمونه، توضیح محلی تولید می‌کند. [۹] در این پروژه هر دو دیدگاه جهانی و محلی به همراه اهمیت جایگشتی و وابستگی جزئی بررسی شده‌اند.

۱-۴. دامنه و محدودیت اولیه

این پژوهش در قالب یک پروژه‌ی آموزشی و با استفاده از یک مجموعه‌داده جدولی با حجم محدود انجام شده است. هدف اصلی آن، بازسازی تصمیم‌های تاریخی مربوط به تأیید یا رد درخواست‌های وام و مقایسه‌ی عملکرد چند روش یادگیری ماشین است؛ بنابراین نتایج آن نباید به‌عنوان یک سامانه‌ی واقعی یا آماده‌ی بهره‌برداری برای اعطای وام تلقی شوند. از آنجا که مجموعه‌داده آزمون فاقد برچسب است، تمامی شاخص‌های ارزیابی مدل‌ها بر اساس مجموعه‌ی نگه‌داشته‌شده از داده‌های آموزشی محاسبه شده‌اند. همچنین، اطلاعات موجود درباره‌ی داده‌ها شامل جزئیاتی از زمان، مکان یا شیوه نمونه‌گیری نیست؛ ازاین‌رو، این پژوهش ادعایی درباره نمایندگی کامل جامعه‌ی آماری یا تعمیم‌پذیری نتایج به سایر جمعیت‌ها مطرح نمی‌کند.

۱-۵. ساختار گزارش

پس از این مقدمه، ساختار گزارش در چهار بخش تنظیم شده است. در بخش دوم، مجموعه‌داده معرفی شده و مراحل بررسی کیفیت داده، تحلیل اکتشافی، مهندسی ویژگی و مقایسه روش‌های مختلف پیش‌پردازش ارائه می‌شود. بخش سوم به فرایند توسعه مدل‌ها اختصاص دارد و شامل آموزش و مقایسه مدل‌های یادگیری ماشین، تنظیم ابرپارامترها، ارزیابی عملکرد با معیارهای مختلف، تحلیل خطا، تفسیرپذیری مدل و تولید پیش‌بینی‌های نهایی است. در نهایت، بخش چهارم مهم‌ترین یافته‌های پژوهش، جمع‌بندی نتایج و محدودیت‌های مطالعه را ارائه می‌کند.

۲. داده و پیش‌پردازش

۲-۱. منبع و ساختار داده

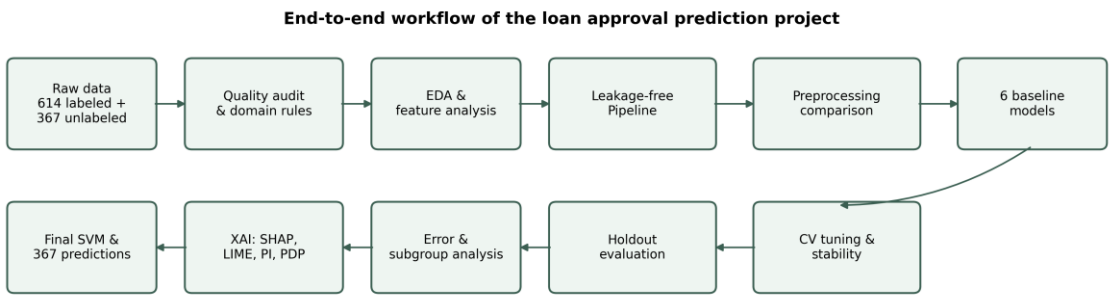
فایل‌های تأییدشده پروژه شامل loan_train.csv و loan_test.csv بودند. داده آموزش ۶۱۴ سطر و ۱۲ ستون شامل متغیر هدف و داده‌ی آزمون ۳۶۷ سطر و ۱۱ ستون بدون متغیر هدف دارد.

جدول ۲ .تعریف متغیرهای مورد استفاده در پروژه

ستون	نوع مفهومی	توضیح
Gender	دسته‌ای دودویی	جنسیت متقاضی
Married	دسته‌ای دودویی	وضعیت تأهل
Dependents	دسته‌ای ترتیبی	تعداد افراد تحت تکفل
Education	دسته‌ای دودویی	وضعیت تحصیلات
Self_Employed	دسته‌ای دودویی	خوداشتغالی
Applicant_Income	عددی پیوسته	درآمد متقاضی
Coapplicant_Income	عددی پیوسته	درآمد متقاضی مشترک
Loan_Amount	عددی پیوسته	مبلغ وام درخواستی
Term	عددی گسسته	مدت بازپرداخت
Credit_History	دودویی	سابقه اعتباری
Area	دسته‌ای اسمی	نوع منطقه سکونت
Status	متغیر هدف	تأیید (Y) یا رد (N) درخواست

۲-۲. جریان کلی تحلیل

شکل ۱ جریان پروژه را نشان می‌دهد. تمام تصمیم‌های پیش‌پردازش و مدل‌سازی فقط با داده‌ی آموزش و اعتبارسنجی گرفته شدند و داده‌ی آزمون تا مرحله نهایی کنار گذاشته شد.



شکل ۱. جریان کلی پروژه از داده خام تا پیش‌بینی نهایی

۲-۳. بررسی کیفیت داده و قواعد دامنه

قبل از شروع مدل‌سازی، ساختار ستون‌ها، مقادیر هدف، ردیف‌های تکراری و دامنه متغیرهای عددی را بررسی کردیم. نتیجه این بررسی در جدول ۳ آمده است. در داده آموزش ردیف تکراری وجود نداشت؛ در داده

آزمون یک ردیف تکراری مشاهده شد. برای حفظ تطابق تعداد و ترتیب خروجی با فایل ورودی، این ردیف در داده آزمون حذف نشد. مبلغ وام نامثبت از نظر دامنه معتبر تلقی نشد و به مقدار گمشده تبدیل شد. درآمدهای منفی و مدت نامثبت مشاهده نشدند.

جدول ۳. نتیجه بررسی کیفیت داده خام

	Dataset	Rows	Columns	Duplicate rows	Nonpositive Loan_Amount	Nonpositive Term	Negative Applicant_Income	Negative Coapplicant_Income
0	Train	614	12	0	21	0	0	0
1	Test	367	11	1	5	0	0	0

۲-۴. آمار توصیفی

جدول ۴ نشان می‌دهد متغیرهای درآمد و مبلغ وام دارای چولگی مثبت شدید هستند. میانگین درآمد متقاضی ۵۴۰.۳۴۶ و میانه‌ی آن ۳۸۱.۲۵۰ است؛ اختلاف زیاد میانگین و میانه و ضریب چولگی ۶/۵۴ حضور مقادیر بسیار بزرگ را تأیید می‌کند. درآمد متقاضی مشترک چولگی بیشتری برابر ۷.۴۹ دارد. مدت بازپرداخت عمدتاً ۳۶۰ است و توزیع آن چولگی منفی دارد.

جدول ۴. آمار توصیفی متغیرهای عددی پس از اعمال قواعد دامنه

	count	mean	median	std	min	25%	50%	75%	max	skewness
t_Income	614.0000	540,345.9283	381,250.0000	610,904.1673	15,000.0000	287,750.0000	381,250.0000	579,500.0000	8,100,000.0000	6.5395
t_Income	614.0000	162,124.5798	118,850.0000	292,624.8369	0.0000	0.0000	118,850.0000	229,725.0000	4,166,700.0000	7.4915
_Amount	593.0000	14,641,821.2479	12,800,000.0000	8,551,513.5014	900,000.0000	10,000,000.0000	12,800,000.0000	16,800,000.0000	70,000,000.0000	2.6796
Term	600.0000	342.0000	360.0000	65.1204	12.0000	360.0000	360.0000	360.0000	480.0000	-2.3624
t_History	564.0000	0.8422	1.0000	0.3649	0.0000	1.0000	1.0000	1.0000	1.0000	-1.8824

۲-۵. مقادیر گمشده و توزیع هدف

بیشترین درصد مقدار گمشده مربوط به سابقه اعتباری با ۸.۱۴ درصد بود. پس از آن خوداشتغالی، مبلغ وام، افراد تحت تکفل، مدت، جنسیت و تأهل قرار داشتند.

جدول ۵. مقادیر گمشده در داده آموزش

متغیر	تعداد گمشده	درصد
Credit_History	۵۰	۸.۱۴
Self_Employed	۳۲	۵.۲۱
Loan_Amount	۲۱	۳.۴۲
Dependents	۱۵	۲.۴۴
Term	۱۴	۲.۲۸
Gender	۱۳	۲.۱۲
Married	۳	۰.۴۹

شکل ۲ توزیع کلاس‌های هدف را در مجموعه‌داده نشان می‌دهد. همان‌طور که مشاهده می‌شود، از مجموع ۶۱۴ درخواست وام، ۴۲۲ درخواست (۶۸/۷۳ درصد) در کلاس تأیید و ۱۹۲ درخواست (۳۱/۲۷ درصد) در

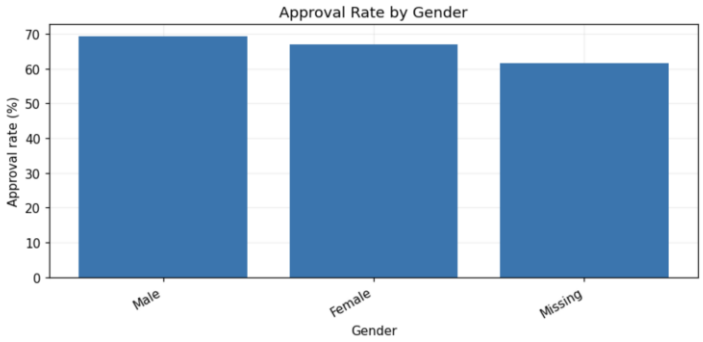
کلاس رد قرار دارند. این توزیع بیانگر آن است که مجموعه‌داده تا حدودی نامتوازن است و کلاس تأیید سهم بیشتری از نمونه‌ها را به خود اختصاص داده است. در چنین شرایطی، یک طبقه‌بند ساده که بدون یادگیری تمام نمونه‌ها را در کلاس اکثریت قرار دهد، به دقتی معادل ۰/۶۸۷۳ دست خواهد یافت. ازاین‌رو، این مقدار به‌عنوان خط مبنای[۲] ارزیابی در نظر گرفته می‌شود و عملکرد مدل‌های یادگیری ماشین با آن مقایسه خواهد شد.



شکل ۲. کیفیت داده و عدم تعادل نسبی کلاس‌ها

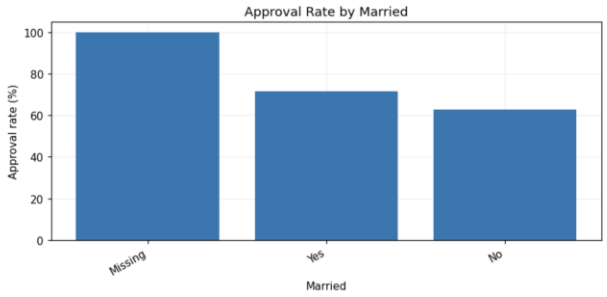
۲-۶. تحلیل اکتشافی روابط با متغیر هدف

تحلیل نرخ تأیید نشان داد تفاوت جنسیتی در داده محدود است: نرخ تأیید مردان ۶۹.۳۳ و زنان ۶۶.۹۶ درصد بود.



شکل ۳. نرخ تأیید بر اساس جنسیت

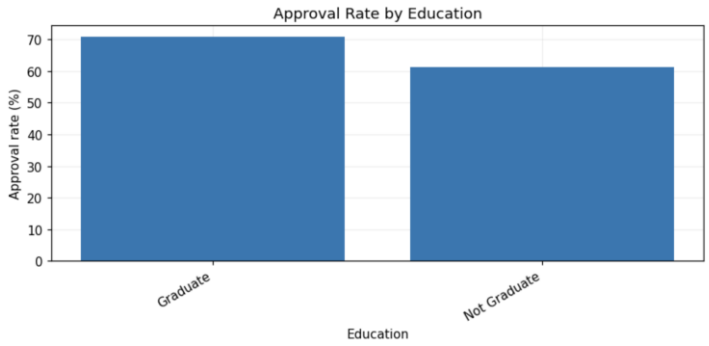
متقاضیان متأهل نرخ ۷۱.۶۱ درصد و متقاضیان مجرد نرخ ۶۲.۹۱ درصد داشتند.



شکل ۴. نرخ تأیید بر اساس وضعیت تأهل

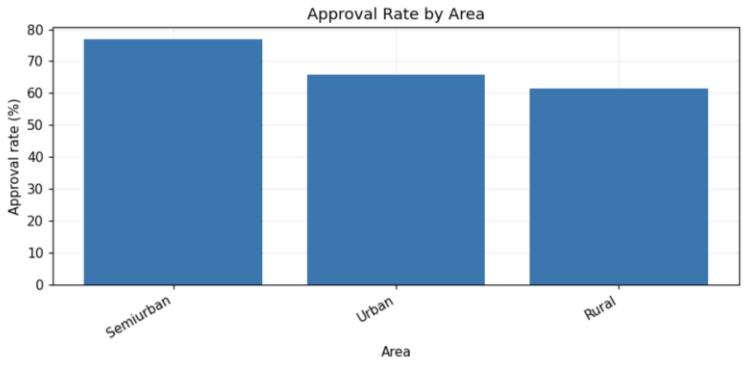
[۲] Base line

فارغ‌التحصیلان با نرخ ۷۰.۸۳ درصد در مقایسه با ۶۱.۱۹ درصد برای گروه غیر فارغ‌التحصیل، نرخ تأیید بالاتری داشتند.



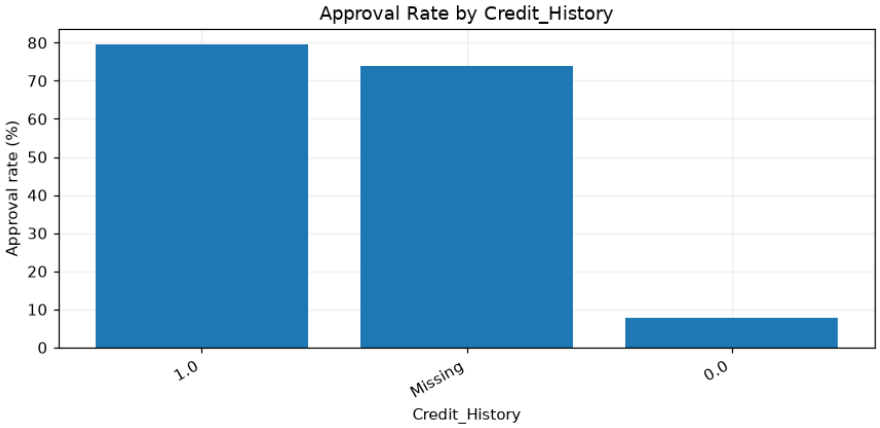
شکل ۵. نرخ تأیید بر اساس تحصیلات

تفاوت مربوط به منطقه و سابقه اعتباری واضح‌تر بود. منطقه نیمه‌شهری نرخ تأیید ۷۶.۸۲ درصد، شهری ۶۵.۸۴ درصد و روستایی ۶۱.۴۵ درصد داشت.



شکل ۶. نرخ تأیید بر اساس محل سکونت

در سابقه اعتباری، نرخ تأیید برای مقدار ۱ برابر ۷۹.۵۸ درصد و برای مقدار ۰ فقط ۷.۸۷ درصد بود. شکل ۷ این تفاوت را نشان می‌دهد. همین بررسی اولیه نشان داد که سابقه اعتباری احتمالاً مهم‌ترین متغیر برای پیش‌بینی خواهد بود.



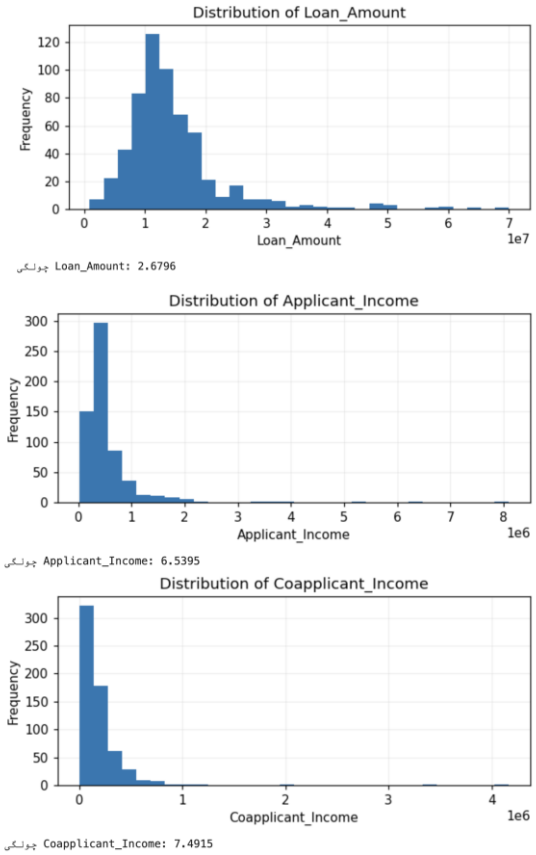
شکل ۷. نرخ تأیید بر اساس سابقه اعتباری

۲-۷. توزیع، چولگی و داده‌های پرت

شکل ۸ توزیع سه متغیر عددی درآمد متقاضی، درآمد متقاضی مشترک و مبلغ وام را نشان می‌دهد. همان‌گونه که در هیستوگرام‌ها مشاهده می‌شود، هر سه متغیر دارای توزیع راست‌چوله هستند و تعداد اندکی از مقادیر بسیار بزرگ، دنباله‌ی توزیع را تشکیل داده‌اند. بر اساس معیار IQR، برای درآمد متقاضی ۵۰ مقدار پرت، برای درآمد متقاضی مشترک ۱۸ مقدار پرت و برای مبلغ وام ۳۹ مقدار پرت شناسایی شد. با این حال، این مقادیر لزوماً خطای ثبت داده محسوب نمی‌شوند و ممکن است بیانگر متقاضیان با درآمد یا مبالغ وام بالا باشند. ازاین‌رو، به‌جای حذف مستقیم آن‌ها، تصمیم‌گیری درباره نحوه مدیریت چولگی و مقادیر پرت به مرحله ارزیابی مدل‌ها موکول شد تا با استفاده از اعتبارسنجی متقابل، مناسب‌ترین روش پیش‌پردازش انتخاب شود.

جدول ۶. شناسایی داده‌های پرت با قاعده IQR

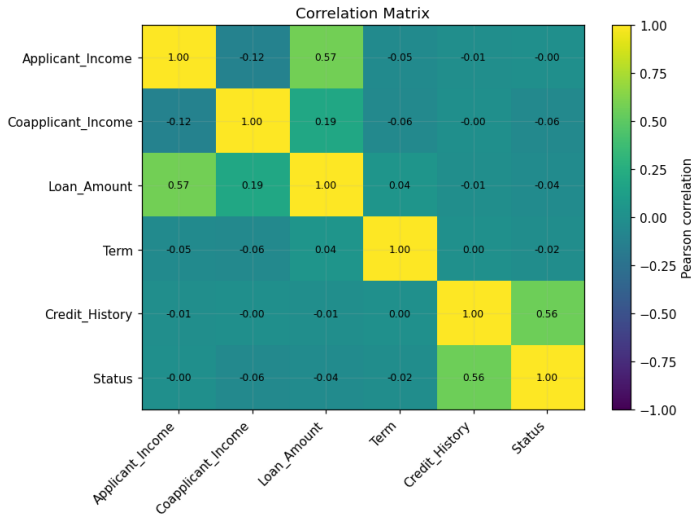
	Feature	Q1	Q3	IQR	Lower bound	Upper bound	Outlier count	Outlier percent
0	Applicant_Income	287,750.0000	579,500.0000	291,750.0000	-149,875.0000	1,017,125.0000	50	8.1433
1	Coapplicant_Income	0.0000	229,725.0000	229,725.0000	-344,587.5000	574,312.5000	18	2.9316
2	Loan_Amount	10,000,000.0000	16,800,000.0000	6,800,000.0000	-200,000.0000	27,000,000.0000	39	6.5767



شکل ۸ .توزیع دو متغیر مالی منتخب

۲-۸. همبستگی متغیرهای عددی

ماتریس همبستگی شکل ۹ نشان داد سابقه‌ی اعتباری با هدف موردنظر همبستگی ۰.۵۶۱۷ دارد؛ سایر همبستگی‌های مستقیم با هدف کوچک‌اند. درآمد متقاضی و مبلغ وام همبستگی ۰.۵۷۰۹ داشتند که نشان می‌دهد مبلغ بالاتر عموماً همراه با درآمد بالاتر درخواست شده است. همبستگی کم ویژگی‌های مالی با هدف به معنای بی‌اهمیتی آن‌ها نیست، زیرا ممکن است اثر آن‌ها غیرخطی یا وابسته به تعامل با ویژگی‌های دیگر باشد.



شکل ۹. ماتریس همبستگی متغیرهای عددی و متغیر هدف

۲-۹. تقسیم داده و جلوگیری از نشت اطلاعات

برای آماده‌سازی داده‌ها، متغیر هدف به‌صورت دودویی کدگذاری شد؛ به‌طوری‌که Y با مقدار ۱ و N با مقدار ۰ نمایش داده شد. سپس داده‌های برچسب‌دار با نسبت ۸۰ به ۲۰ و با استفاده از نمونه‌گیری طبقه‌بندی‌شده[۳] به دو بخش آموزش و مجموعه‌ی نگه‌داشته‌شده تقسیم شدند. در نتیجه، ۴۹۱ نمونه برای آموزش مدل‌ها و ۱۲۳ نمونه برای ارزیابی نهایی کنار گذاشته شد. نسبت کلاس مثبت در کل مجموعه‌داده ۰/۶۸۷۳، در مجموعه‌ی آموزش ۰/۶۸۶۴ و در مجموعه‌ی نگه‌داشته‌شده ۰/۶۹۱۱ بود که نشان می‌دهد تقسیم‌بندی انجام‌شده، توزیع کلاس‌ها را به‌خوبی حفظ کرده است. همچنین، تمامی مراحل پیش‌پردازش شامل جای‌گذاری مقادیر گمشده، مقیاس‌بندی، کدگذاری متغیرهای طبقه‌ای و روش‌های نمونه‌برداری در قالب یک Pipeline پیاده‌سازی شدند. به این ترتیب، در هرتکرار اعتبارسنجی متقابل، این عملیات تنها بر روی داده‌های آموزش همان تکرار برازش شده و سپس روی داده‌های اعتبارسنجی اعمال شدند؛ در نتیجه از نشت اطلاعات[۴] میان داده‌های آموزش و اعتبارسنجی جلوگیری شد.

---

[۳] Stratified

[۴] Data leakage

۲-۱۰. مهندسی ویژگی

به‌منظور افزایش توان توصیفی داده‌ها، چهار ویژگی جدید در داخل Pipeline و پیش از آموزش مدل‌ها تولید شدند. سه ویژگی اصلی به شرح زیر هستند:

$$\text{Total Income} = \text{Applicant Income} + \text{Coapplicant Income} \qquad (1)$$

$$\text{Loan-to-Income Ratio} = \frac{\text{Loan Amount}}{\text{Total Income}} \qquad (2)$$

$$\text{Loan Amount per Term} = \frac{\text{Loan Amount}}{\text{Loan Term}} \qquad (3)$$

این ویژگی‌ها به‌ترتیب بیانگر توان مالی خانوار، نسبت مبلغ وام به درآمد و فشار تقریبی بازپرداخت وام در هرواحد از دوره‌ی بازپرداخت هستند. از آنجا که این متغیرها درون Pipeline ساخته شدند، در هرتکرار اعتبارسنجی متقابل تنها با استفاده از داده‌های آموزش همان تکرار محاسبه شدند؛ بنابراین هیچ اطلاعاتی از مجموعه‌ی اعتبارسنجی وارد فرایند آموزش نشد و خطر نشت اطلاعات به حداقل رسید.

۲-۱۱. مقایسه روش‌های پیش‌پردازش

به‌منظور مقایسه منصفانه‌ی روش‌های مختلف پیش‌پردازش، در تمامی آزمایش‌ها از رگرسیون لجستیک به‌عنوان مدل مرجع استفاده شد تا اثر تغییرات پیش‌پردازش، مستقل از نوع مدل یادگیری ماشین ارزیابی شود. معیار اصلی مقایسه، میانگین امتیاز F1 در اعتبارسنجی متقابل بود، زیرا این معیار با درنظرگرفتن هم‌زمان دقت و فراخوانی، برای داده‌های نسبتاً نامتوازن مناسب‌تر از دقت[۵] است. علاوه بر این، انحراف معیار F1 نیز گزارش شد تا میزان پایداری عملکرد هرروش در تکرارهای مختلف اعتبارسنجی متقابل ارزیابی شود.

۲-۱۱-۱. جای‌گذاری مقادیر گمشده

سه روش میانگین، میانه و KNN Imputation مقایسه شدند. جدول ۷ نشان می‌دهد جای‌گذاری میانگین با F1 برابر ۰.۸۶۲۱ کمی بهتر از دو روش دیگر بود. برای متغیرهای دسته‌ای در همه‌ی سناریوها از پرتکرارترین مقدار استفاده شد.

جدول ۷. مقایسه روش‌های جای‌گذاری

روش	دقت متوازن[۶]	فراخوانی[۷]	میانگین F1 ± انحراف معیار	ROC-AUC
میانگین	۰/۶۸۲۳	۰/۹۶۴۴	۰/۸۶۲۱ ± ۰/۰۰۱۱	۰/۷۳۵۲
KNN	۰/۶۸۲۳	۰/۹۵۵۶	۰/۸۵۸۶ ± ۰/۰۰۵۴	۰/۷۳۰۴
میانه	۰/۶۷۷۳	۰/۹۵۸۵	۰/۸۵۷۹ ± ۰/۰۰۷۰	۰/۷۳۲۴

[۵] Accuracy

[۶] Balanced accuracy

[۷] Recall

۲-۱۱-۲. مقیاس‌بندی

چهار حالت استانداردسازی[۸]، حداقل حداکثر[۹]، مقاوم[۱۰] و بدون مقیاس‌بندی[۱۱] مقایسه شد. جدول ۸ نشان می‌دهد مقیاس‌بندی حداقل ـ حداکثر بیشترین F1 و ROC-AUC را داشت. نبود مقیاس‌بندی، F1 را به ۰.۸۰۴۸ و ROC-AUC را به ۰.۴۳۰۹ کاهش داد؛ این افت اهمیت مقیاس برای مدل‌های حساس به فاصله یا حاشیه را نشان می‌دهد.

جدول ۸. مقایسه روش‌های مقیاس‌بندی

روش	دقت	دقت متوازن	میانگین F1 ± انحراف معیار	ROC-AUC
حداقل ـ حداکثر	۰/۷۹۲۲	۰/۶۸۴۸	± ۰/۸۶۵۵ ۰/۰۰۷۳	۰/۷۴۴۱
مقاوم	۰/۷۸۸۲	۰/۶۸۱۸	± ۰/۸۶۲۵ ۰/۰۰۴۲	۰/۷۳۵۰
استاندارد	۰/۷۸۸۲	۰/۶۸۳۵	± ۰/۸۶۲۱ ۰/۰۰۱۱	۰/۷۳۵۲
بدون مقیاس‌بندی	۰/۶۷۴۲	۰/۴۹۲۹	± ۰/۸۰۴۸ ۰/۰۰۸۴	۰/۴۳۰۹

۲-۱۱-۳. مدیریت چولگی و داده‌های پرت

برای مدیریت چولگی متغیرهای عددی، چهار سناریوی پیش‌پردازش شامل عدم اعمال تبدیل، تبدیل لگاریتمی[۱۲]، وینسورسازی در صدک‌های ۱ و ۹۹ و ترکیب وینسورسازی با تبدیل لگاریتمی مقایسه شدند. نتایج اعتبارسنجی متقابل نشان داد سه روش log1p، وینسورسازی و ترکیب وینسورسازی با log1p عملکردی تقریباً یکسان داشته و همگی میانگین F1 برابر با ۰/۸۶۷۰ به دست آوردند، در حالی که استفاده نکردن از هیچ تبدیلی میانگین F1 را به ۰/۸۶۵۵ کاهش داد. با توجه به اینکه میانگین F1 از ابتدا به‌عنوان معیار اصلی انتخاب روش پیش‌پردازش تعیین شده بود، تبدیل log1p به دلیل سادگی، حفظ کامل نمونه‌ها و کاهش چولگی داده‌ها به‌عنوان گزینه‌ی نهایی انتخاب شد. اگرچه روش وینسورسازی در معیارهایROC-AUC و به‌ویژه PR-AUC عملکرد اندکی بهتر نشان داد، اما این اختلاف ناچیز بود و تغییری در نتیجه انتخاب بر اساس معیار از پیش تعیین‌شده ایجاد نکرد..

---

[۸] Standard

[۹] Minmax

[۱۰] Robust

[۱۱] None

[۱۲] log1p

جدول ۹. مقایسه سناریوهای مدیریت چولگی و داده پرت

سناریو	دقت	دقت متوازن	F1	PR-AUC
تبدیل log1p	۰/۷۹۴۳	۰/۶۸۶۳	۰/۸۶۷۰	۰/۸۳۸۷
وینسورسازی	۰/۷۹۴۳	۰/۶۸۶۳	۰/۸۶۷۰	۰/۸۴۵۲
وینسورسازی و لگاریتم	۰/۷۹۴۳	۰/۶۸۶۳	۰/۸۶۷۰	۰/۸۳۹۶
بدون تغییر	۰/۷۹۲۲	۰/۶۸۴۸	۰/۸۶۵۵	۰/۸۳۹۵

۲-۱۱-۴. مدیریت عدم تعادل کلاس

چهار روش شامل عدم نمونه‌برداری، نمونه‌برداری تصادفی افزایشی، SMOTE و وزن‌دهی متوازن کلاس مقایسه شدند. نتایج نشان داد عدم نمونه‌برداری با میانگین F1 برابر ۰/۸۶۷۰ بهترین عملکرد را داشت و به‌عنوان روش نهایی انتخاب شد. اگرچه SMOTE دقت متوازن را اندکی بهبود داد، اما به دلیل کاهش Recall و F1 انتخاب نشد. این نتایج نشان می‌دهد نامتوازن بودن داده‌ها (حدود ۶۹ به ۳۱) به اندازه‌ای نبود که استفاده از روش‌های متعادل‌سازی، عملکرد مدل را بهبود دهد.

جدول ۱۰. مقایسه روش‌های مدیریت عدم تعادل

روش	دقت	دقت متوازن	دقت مثبت	فراخوانی	F1
بدون نمونه‌برداری	۰/۷۹۴۳	۰/۶۸۶۳	۰/۷۷۹۹	۰/۹۷۶۳	۰/۸۶۷۰
SMOTE	۰/۷۵۳۵	۰/۶۸۹۹	۰/۷۹۶۸	۰/۸۶۰۵	۰/۸۲۷۴
وزن کلاس	۰/۷۲۵۰	۰/۶۷۱۱	۰/۷۹۰۶	۰/۸۱۶۰	۰/۸۰۲۹
نمونه‌برداری تصادفی	۰/۷۲۳۰	۰/۶۷۶۷	۰/۷۹۷۰	۰/۸۰۱۲	۰/۷۹۸۹

۲-۱۲. پایپ‌لاین نهایی پیش‌پردازش

پایپ‌لاین منتخب شامل قواعد جدول ۱۱ است.

جدول ۱۱. تصمیم نهایی اجزای پیش‌پردازش

مؤلفه	روش منتخب
جای‌گذاری عددی	میانگین
جای‌گذاری دسته‌ای	پرتکرارترین مقدار
مقیاس‌بندی	حداقل ـ حداکثر

مؤلفه	روش منتخب
مدیریت چولگی	تبدیل p1log
مدیریت عدم تعادل	بدون نمونه‌برداری
کدگذاری دسته‌ای	One-Hot Encoding

۳. مدل‌سازی، ارزیابی و نتایج

۳-۱. مدل‌های بررسی‌شده

برای اینکه مقایسه فقط به یک خانواده از الگوریتم‌ها محدود نشود، شش مدل زیر انتخاب شدند:

- رگرسیون لجستیک: مدل خطی و قابل تفسیر به‌عنوان مبنای قوی؛
- نزدیک‌ترین همسایه: مدل مبتنی بر فاصله و یادگیرنده تنبل[۱۳]؛
- ماشین بردار پشتیبان: مدل حاشیه‌محور مناسب داده‌های کوچک و متوسط؛
- درخت تصمیم: مدل غیرخطی و قاعده‌محور؛
- جنگل تصادفی: مدل تجمیعی مبتنی بر چند درخت؛
- گرادیان بوستینگ: مدل بوستینگ ترتیبی با توان مدل‌سازی روابط غیرخطی.

۳-۲. تنظیمات آزمایش و اعتبارسنجی

برای مقایسه‌ی اولیه و جست‌وجوی ابرپارامتر از اعتبارسنجی متقابل طبقه‌بندی‌شده سه‌بخشی با درهم‌ریزی و بذر تصادفی ۴۲ استفاده شد. معیار جست‌وجو F کلاس تأیید بود. برای رگرسیون لجستیک، KNN، SVM و درخت تصمیم از GridSearchCV و برای جنگل تصادفی و گرادیان بوستینگ از RandomizedSearchCV استفاده شد. فضای جست‌وجو در جدول ۱۲ آمده است.

جدول ۱۲. فضای تنظیم ابرپارامتر مدل‌ها

مدل	روش جست‌وجو	فضای پارامترها
رگرسیون لجستیک	شبکه‌ای	**C**: {۰.۱, ۱, ۱۰} **class_weight**: {None, balanced}
KNN	شبکه‌ای	**n_neighbors**: {۵, ۹, ۱۵} **weights**: {uniform, distance}
SVM	شبکه‌ای	**C**: {۰.۱, ۱, ۱۰} **class_weight**: {None, balanced}
درخت تصمیم	شبکه‌ای	**max_depth**: {۳, ۵, ۸, None} **class_weight**: {None, balanced}

[۱۳] Lazy learner

مدل	روش جست‌وجو	فضای پارامترها
جنگل تصادفی	تصادفی، ۵ حالت	**n_estimators**: {۱۰۰, ۲۰۰} **max_depth**: {None, ۵, ۱۰} **min_samples_leaf**: {۱, ۴} **max_features**: {√p, ۰.۷p} **class_weight**: {None, balanced}
گرادیان بوستینگ	تصادفی، ۵ حالت	پارامترهای تعریف‌شده در کد (مانند **n_estimators**، **learning_rate**، **max_depth**و...)

پس از تنظیم، چهار مدل برتر با اعتبارسنجی متقابل تکرارشونده شامل ۵ بخش و ۳ تکرار ارزیابی شدند. انتخاب مدل نهایی فقط بر پایه‌ی این ارزیابی روی داده آموزش بود؛ مجموعه‌ی نگه‌داشته‌شده در انتخاب مدل دخالت نداشت.

۳-۴. معیارهای ارزیابی

با در نظر گرفتن کلاس ۷ به‌عنوان کلاس مثبت، معیارهای ارزیابی شامل Accuracy، Precision، Recall، F1، Balanced Accuracy، ROC-AUC و PR-AUC محاسبه شدند. روابط ریاضی این معیارها در روابط (۴) تا (۸) ارائه شده است. از آنجا که داده‌ها تا حدی نامتوازن بودند، اتکا به Accuracy به‌تنهایی می‌توانست تصویری خوش‌بینانه از عملکرد مدل ارائه دهد. به همین دلیل، Precision برای سنجش صحت پیش‌بینی‌های مثبت، Recall برای ارزیابی توان مدل در شناسایی نمونه‌های مثبت و F1 برای ایجاد تعادل بین این دو معیار مورد توجه قرار گرفت. همچنین، ROC-AUC توانایی کلی مدل در تفکیک کلاس‌ها و PR-AUC عملکرد آن را بر روی کلاس مثبت، به‌ویژه در شرایط عدم تعادل داده‌ها، نشان می‌دهد.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \qquad (4)$$

$$\text{Precision} = \frac{TP}{TP + FP} \qquad (5)$$

$$\text{Recall} = \frac{TP}{TP + FN} \qquad (6)$$

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \qquad (7)$$

۳-۵. عملکرد مدل‌های مبنا

نتایج مدل‌های اولیه در جدول ۱۳ آمده است. جنگل تصادفی بیشترین F1 نگه‌داشته‌شده را با ۰/۹۰۴۰ به دست آورد، در حالی که SVM و رگرسیون لجستیک هر دو ۰/۹۰۳۲ داشتند. با این حال، یک نتیجه روی مجموعه نگه‌داشته‌شده برای انتخاب نهایی کافی نبود؛ به همین دلیل تنظیم ابرپارامتر و تحلیل پایداری را ادامه دادیم.

جدول ۱۳. نتایج مدل‌های مبنا پیش از تنظیم ابرپارامتر

مدل	CV-F1	دقت	دقت متوازن	دقت مثبت	فراخوانی	F1	ROC-AUC
SVM	۰/۸۷۰۰	۰/۸۵۳۷	۰/۷۷۰۴	۰/۸۳۱۷	۰/۹۸۸۲	۰/۹۰۳۲	۰/۷۷۵۵
رگرسیون لجستیک	۰/۸۶۷۰	۰/۸۵۳۷	۰/۷۷۰۴	۰/۸۳۱۷	۰/۹۸۸۲	۰/۹۰۳۲	۰/۸۵۶۷
جنگل تصادفی	۰/۸۵۳۰	۰/۸۶۱۸	۰/۸۱۲۷	۰/۸۶۹۶	۰/۹۴۱۲	۰/۹۰۴۰	۰/۸۴۹۲
گرادیان بوستینگ	۰/۸۴۶۶	۰/۸۳۷۴	۰/۷۸۰۵	۰/۸۴۹۵	۰/۹۲۹۴	۰/۸۸۷۶	۰/۸۱۲۱
KNN	۰/۸۰۷۹	۰/۷۳۱۷	۰/۶۲۴۰	۰/۷۵۴۹	۰/۹۰۵۹	۰/۸۲۳۵	۰/۶۹۲۹
درخت تصمیم	۰/۷۸۹۱	۰/۷۶۴۲	۰/۷۶۳۹	۰/۸۷۸۴	۰/۷۶۴۷	۰/۸۱۷۶	۰/۷۶۳۹

۳-۶. نتایج تنظیم ابرپارامتر

پس از تنظیم ابرپارامترها، بهترین تنظیمات برای هرمدل انتخاب شد. در رگرسیون لجستیک و SVM، مقدار C=1 بدون استفاده از وزن‌دهی کلاس بهترین عملکرد را داشت. برای KNN، استفاده از ۱۵ همسایه با وزن‌دهی فاصله‌ای انتخاب شد. در درخت تصمیم، عمق ۳ همراه با وزن‌دهی متوازن کلاس‌ها بهترین نتیجه را ایجاد کرد. همچنین، جنگل تصادفی با ۱۰۰ درخت، انتخاب ویژگی به روش $\sqrt{p}$ ، بدون محدودیت عمق و وزن‌دهی متوازن عملکرد بهتری داشت. برای گرادیان بوستینگ نیز ۵۰ برآوردگر، نرخ یادگیری ۰/۰۵، عمق ۱ و استفاده از تمام نمونه‌ها در هرمرحله به‌عنوان بهترین تنظیمات انتخاب شدن.

همان‌طور که در جدول ۱۴ مشاهده می‌شود، گرادیان بوستینگ روی مجموعه‌ی نگه‌داشته‌شده[۱۴] با F1 برابر ۰/۹۱۳۰ بهترین عملکرد را ثبت کرد، در حالی که رگرسیون لجستیک با PR-AUC برابر ۰/۹۲۰۱ بالاترین مقدار این معیار را به دست آورد. با این حال، از آنجا که این مجموعه داده تنها برای ارزیابی نهایی و مستقل

[۱۴] Hold-out test set

در نظر گرفته شده بود، نتایج آن مبنای انتخاب مدل قرار نگرفت و صرفاً برای گزارش عملکرد نهایی مدل‌ها استفاده شد.

جدول ۱۴. مقایسه مدل‌های تنظیم‌شده روی مجموعه نگه‌داشته‌شده

مدل	CV-F1	دقت	دقت متوازن	دقت مثبت	فراخوانی	F1	ROC-AUC	PR-AUC
گرادیان بوستینگ	۰/۸۷۰۰	۰/۸۶۹۹	۰/۷۹۶۷	۰/۸۴۸۵	۰/۹۸۸۲	۰/۹۱۳۰	۰/۸۵۹۱	۰/۸۹۴۱
SVM	۰/۸۷۰۰	۰/۸۵۳۷	۰/۷۷۰۴	۰/۸۳۱۷	۰/۹۸۸۲	۰/۹۰۳۲	۰/۷۷۵۵	۰/۸۵۹۲
درخت تصمیم	۰/۸۶۹۳	۰/۸۵۳۷	۰/۷۹۲۳	۰/۸۵۲۶	۰/۹۵۲۹	۰/۹۰۰۰	۰/۸۳۰۵	۰/۸۷۳۲
رگرسیون لجستیک	۰/۸۶۷۰	۰/۸۵۳۷	۰/۷۷۰۴	۰/۸۳۱۷	۰/۹۸۸۲	۰/۹۰۳۲	۰/۸۵۸۸	۰/۹۲۰۱
جنگل تصادفی	۰/۸۴۹۹	۰/۸۳۷۴	۰/۷۷۳۲	۰/۸۴۲۱	۰/۹۴۱۲	۰/۸۸۸۹	۰/۸۴۷۱	۰/۸۹۶۱
KNN	۰/۸۲۷۹	۰/۷۴۸۰	۰/۶۱۳۹	۰/۷۴۵۵	۰/۹۶۴۷	۰/۸۴۱۰	۰/۷۳۸۱	۰/۸۵۲۰

۳-۷. اثر تنظیم ابرپارامتر

همان‌طور که در جدول ۱۵ مشاهده می‌شود، بیشترین اثر تنظیم ابرپارامترها مربوط به درخت تصمیم بود؛ به‌طوری که میانگین F1 در اعتبارسنجی متقابل ۰/۰۸۰۲ و F1 مجموعه نگه‌داشته‌شده ۰/۰۸۲۴ افزایش یافت .گرادیان بوستینگ و KNN نیز پس از تنظیم ابرپارامترها بهبود عملکرد را نشان دادند. در مقابل، جنگل تصادفی با وجود استفاده از جست‌وجوی تصادفی، روی مجموعه نگه‌داشته‌شده عملکرد ضعیف‌تری نسبت به قبل داشت. این نتایج نشان می‌دهد که تنظیم ابرپارامترها همیشه به بهبود عملکرد مدل منجر نمی‌شود و اثربخشی آن باید با استفاده از اعتبارسنجی مناسب ارزیابی و تأیید شود.

جدول ۱۵. تغییر عملکرد پیش و پس از تنظیم

مدل	CV- F1 قبل	CV- F1 بعد	F1 قبل	F1 بعد
SVM	۰/۸۷۰۰	۰/۸۷۰۰	۰/۹۰۳۲	۰/۹۰۳۲
گرادیان بوستینگ	۰/۸۴۶۶	۰/۸۷۰۰	۰/۸۸۷۶	۰/۹۱۳۰
درخت تصمیم	۰/۷۸۹۱	۰/۸۶۹۳	۰/۸۱۷۶	۰/۹۰۰۰
رگرسیون لجستیک	۰/۸۶۷۰	۰/۸۶۷۰	۰/۹۰۳۲	۰/۹۰۳۲
جنگل تصادفی	۰/۸۵۳۰	۰/۸۴۹۹	۰/۹۰۴۰	۰/۸۸۸۹
KNN	۰/۸۰۷۹	۰/۸۲۷۹	۰/۸۲۳۵	۰/۸۴۱۰

۳-۸. تحلیل پایداری و انتخاب مدل نهایی

برای مقایسه‌ی نهایی مدل‌ها، چهار مدل برتر با استفاده از اعتبارسنجی متقابل تکرارشونده‌ی ۵ بخشی و ۳ تکرار ارزیابی شدند. همان‌طور که در جدول ۱۶ مشاهده می‌شود، SVM با میانگین F1 برابر ۰/۸۷۰۷

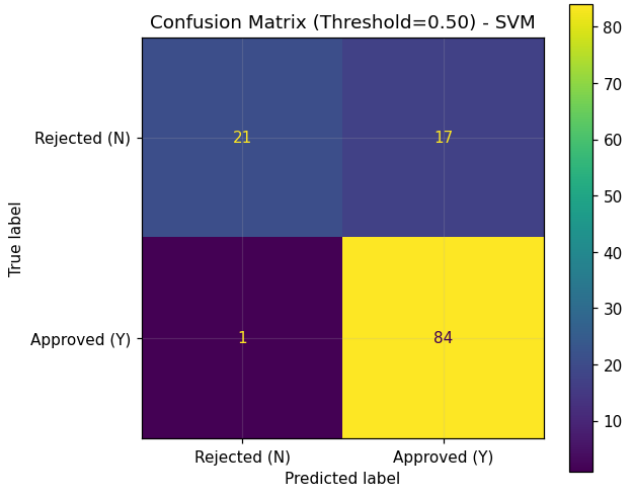
بهترین عملکرد را به دست آورد، هرچند اختلاف آن با گرادیان بوستینگ تنها ۰/۰۰۰۶ بود. در مقابل، درخت تصمیم با وجود عملکرد مناسب، نوسان بیشتری بین تکرارها داشت که از انحراف معیار بالاتر آن مشخص است. با توجه به اینکه میانگین F1 در اعتبارسنجی متقابل از ابتدا به‌عنوان معیار اصلی انتخاب مدل تعیین شده بود، SVM به‌عنوان مدل نهایی انتخاب شد. این انتخاب به معنای برتری مطلق SVM نیست، بلکه نشان می‌دهد این مدل در تقسیم‌بندی‌های مختلف داده، عملکردی اندکی پایدارتر و سازگارتر نسبت به سایر مدل‌های رقیب داشته است.

جدول ۱۶. تحلیل پایداری مدل‌های برتر

مدل	میانگین F1	انحراف معیار F1	دقت متوازن	PR-AUC
SVM	۰/۸۷۰۷	۰/۰۲۱۳	۰/۶۹۰۴	۰/۸۱۱۸
گرادیان بوستینگ	۰/۸۷۰۱	۰/۰۲۰۸	۰/۶۹۰۰	۰/۸۰۳۱
رگرسیون لجستیک	۰/۸۶۷۱	۰/۰۱۹۷	۰/۶۸۷۶	۰/۸۳۳۹
درخت تصمیم	۰/۸۴۲۰	۰/۰۷۰۲	۰/۶۸۱۳	۰/۷۸۳۱

۳-۹. ارزیابی مدل منتخب روی مجموعه نگه‌داشته‌شده

با استفاده از آستانه‌ی پیش‌فرض ۰/۵، مدل SVM به Accuracy برابر ۰/۸۵۳۷، Balanced Accuracy برابر ۰/۷۷۰۴، Precision برابر ۰/۸۳۱۷، Recall برابر ۰/۹۸۸۲، F1 برابر ۰/۹۰۳۲، ROC-AUC برابر ۰/۷۷۵۵ و PR-AUC برابر ۰/۸۵۹۲ دست یافت. همان‌طور که در شکل ۶ مشاهده می‌شود، ماتریس اغتشاش شامل ۲۱ منفی صحیح، ۱۷ مثبت کاذب، ۱ منفی کاذب و ۸۴ مثبت صحیح است. مقدار بسیار بالای Recall نشان می‌دهد که مدل تقریباً همه نمونه‌های متعلق به کلاس تأیید را به‌درستی شناسایی کرده است. در مقابل، وجود ۱۷ مثبت کاذب نشان می‌دهد که بخشی از درخواست‌های ردشده نیز به اشتباه در کلاس تأیید قرار گرفته‌اند.



شکل ۱۰. ماتریس درهم‌ریختگی SVM

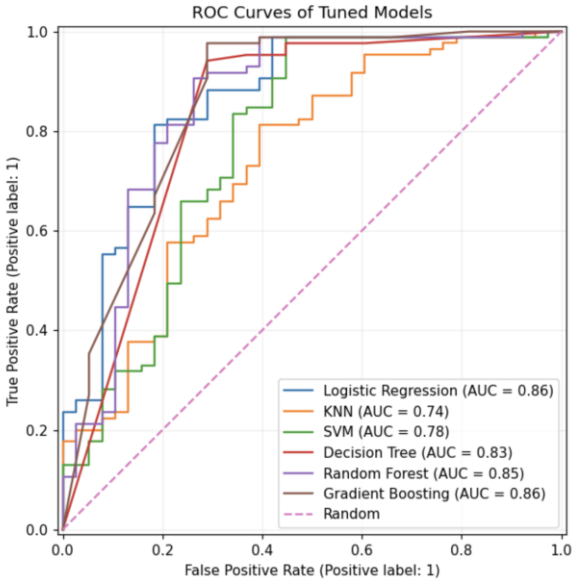
همان‌طور که در جدول ۱۷ مشاهده می‌شود، گرادیان بوستینگ از نظر توزیع خطاهای طبقه‌بندی، بهترین عملکرد را روی مجموعه نگه‌داشته‌شده نشان داد. با این حال، همان‌طور که پیش‌تر بیان شد، انتخاب مدل نهایی بر اساس نتایج اعتبارسنجی متقابل تکرارشونده روی داده‌های آموزش انجام شد، نه عملکرد مجموعه‌ی نگه‌داشته‌شده. همچنین، KNN بیشترین تعداد مثبت کاذب را ایجاد کرد، در حالی که درخت تصمیم کمترین تعداد مثبت کاذب را داشت، اما این کاهش با افزایش تعداد منفی کاذب همراه بود. این موضوع می‌تواند نشان‌دهنده‌ی این باشد که کاهش یک نوع خطا معمولاً با افزایش نوع دیگری از خطا همراه است و انتخاب مدل به توازن میان این خطاها بستگی دارد.

جدول ۱۷. مقایسه اجزای ماتریس درهم‌ریختگی مدل‌های تنظیم‌شده

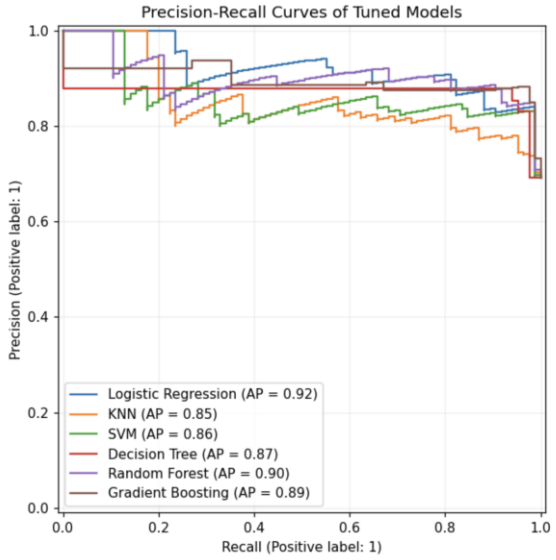
مدل	TN	FP	FN	TP	F1	دقت متوازن
گرادیان بوستینگ	۲۳	۱۵	۱	۸۴	۰/۹۱۳۰	۰/۷۹۶۷
رگرسیون لجستیک	۲۱	۱۷	۱	۸۴	۰/۹۰۳۲	۰/۷۷۰۴
SVM	۲۱	۱۷	۱	۸۴	۰/۹۰۳۲	۰/۷۷۰۴
درخت تصمیم	۲۴	۱۴	۴	۸۱	۰/۹۰۰۰	۰/۷۹۲۳
جنگل تصادفی	۲۳	۱۵	۵	۸۰	۰/۸۸۸۹	۰/۷۷۳۲
KNN	۱۰	۲۸	۳	۸۲	۰/۸۴۱۰	۰/۶۱۳۹

۳-۱۰. منحنی‌های ROC و دقت ـ فراخوانی

شکل ۱۱ منحنی‌های ROC و Precision–Recall مربوط به مدل‌های تنظیم‌شده را نشان می‌دهد. همان‌طور که مشاهده می‌شود، رگرسیون لجستیک و گرادیان بوستینگ از نظر ROC-AUC و PR-AUC عملکرد بهتری نسبت به SVM داشتند. این نتایج نشان می‌دهد که اگرچه SVM بر اساس معیار از پیش تعیین‌شده، یعنی میانگین F1 در اعتبارسنجی متقابل تکرارشونده، به‌عنوان مدل نهایی انتخاب شد، اما در رتبه‌بندی نمونه‌ها بر اساس امتیازهای پیش‌بینی نسبت به برخی مدل‌های دیگر عملکرد ضعیف‌تری داشت. بنابراین، انتخاب مدل مناسب به هدف مسئله و هزینه‌ی انواع خطا بستگی دارد و ممکن است بسته به کاربرد، معیار ارزیابی متفاوتی مبنای تصمیم‌گیری قرار گیرد.



شکل ۱۱. مقایسه نمودارهای ROC



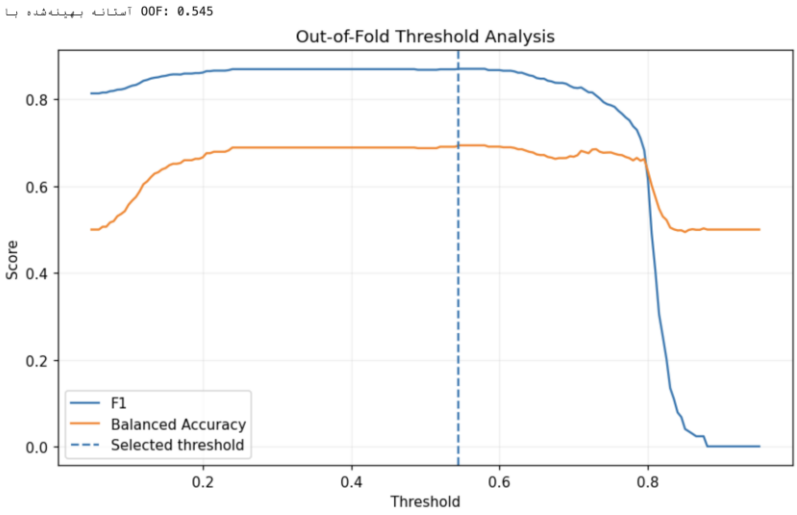
شکل ۱۲. مقایسه مدل‌های تنظیم‌شده

۳-۱۱. تنظیم آستانه تصمیم

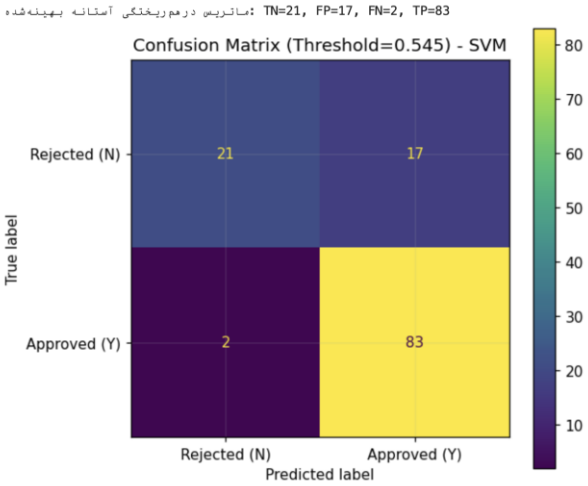
برای جلوگیری از نشت اطلاعات در فرآیند تعیین آستانه‌ی تصمیم، آستانه‌ی بهینه بر اساس احتمال‌های خارج از نمونه[۱۵] حاصل از داده‌های آموزش محاسبه شد و از مجموعه‌ی نگه‌داشته‌شده در این مرحله استفاده نشد. آستانه‌ی بهینه از نظر F1 برابر ۰/۵۴۵ به دست آمد. اعمال این آستانه روی مجموعه‌ی نگه‌داشته‌شده به Accuracy برابر ۰/۸۴۵۵، Recall برابر ۰/۹۷۶۵ و F1 برابر ۰/۸۹۷۳ منجر شد. در مقایسه با آستانه‌ی پیش‌فرض ۰/۵، تعداد منفی‌های کاذب از ۱ به ۲ افزایش یافت، در حالی که تعداد مثبت‌های کاذب تغییری نکرد. بنابراین، اگرچه آستانه‌ی انتخاب‌شده بر پایه داده‌های آموزش از نظر روش‌شناسی صحیح و عاری از نشت

[۱۵] Out-of-fold

اطلاعات بود، اما در این مجموعه‌ی نگه‌داشته‌شده‌ی کوچک نتوانست عملکرد مدل را نسبت به آستانه‌ی پیش‌فرض بهبود دهد.



شکل ۱۳. تحلیل آستانه با پیش‌بینی‌های خارج از نمونه



شکل ۱۴. ماتریس درهم‌ریختگی پس از تغییر آستانه

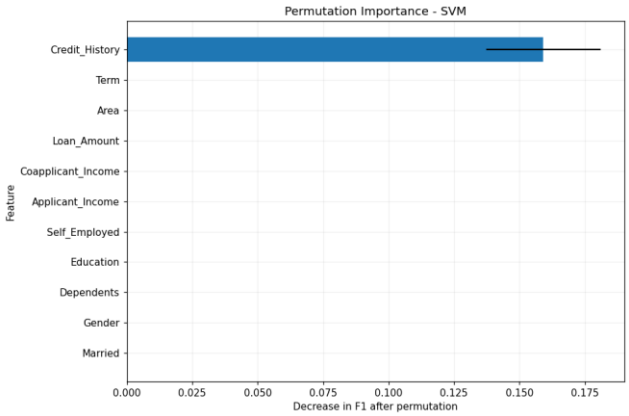
۳-۱۲. تحلیل خطاها

با آستانه‌ی ۰/۵۴۵، ۱۰۴ نمونه درست، ۱۷ مثبت کاذب و ۲ منفی کاذب وجود داشت. همه‌ی ۱۷ مثبت کاذب دارای سابقه‌ی اعتباری ۱ بودند؛ این الگو نشان می‌دهد مدل در حضور سابقه‌ی اعتباری مطلوب، تمایل زیادی به تأیید دارد و عوامل بازدارنده‌ی دیگر را کمتر وزن می‌دهد. در گروه روستایی ۱۰ مثبت کاذب از ۳۴ نمونه مشاهده شد، در حالی که منطقه‌ی نیمه‌شهری فقط ۲ مثبت کاذب از ۴۹ نمونه داشت.

دو منفی کاذب شامل یک متقاضی با سابقه‌ی اعتباری ۰ و احتمال ۰/۰۸۸۹ و یک متقاضی با سابقه‌ی اعتباری ۱ و احتمال ۰/۴۹۳۱ بودند. نمونه‌ی دوم نزدیک آستانه قرار داشت و نشان‌دهنده‌ی حساسیت تصمیم به انتخاب آستانه است. میانگین مبلغ وام مثبت‌های کاذب از نمونه‌های درست بیشتر بود، اما تعداد کم خطاها مانع نتیجه‌گیری آماری قطعی است.

۳-۱۳. اهمیت ویژگی‌ها با روش جایگشتی

در اهمیت جایگشتی روی مجموعه‌ی نگه‌داشته‌شده، به‌هم‌ریختن سابقه‌ی اعتباری موجب کاهش میانگین F1 به اندازه‌ی ۰/۱۵۹۱ شد، در حالی که کاهش میانگین سایر ویژگی‌های خام در این نمونه نزدیک صفر بود. این نتیجه با تحلیل اکتشافی و همبستگی سازگار است، اما به معنای بی‌اثر بودن قطعی سایر ویژگی‌ها نیست؛ در داده‌ی کوچک و با ویژگی غالب، اهمیت جایگشتی می‌تواند سهم ویژگی‌های هم‌بسته یا ضعیف‌تر را کم‌برآورد کند.



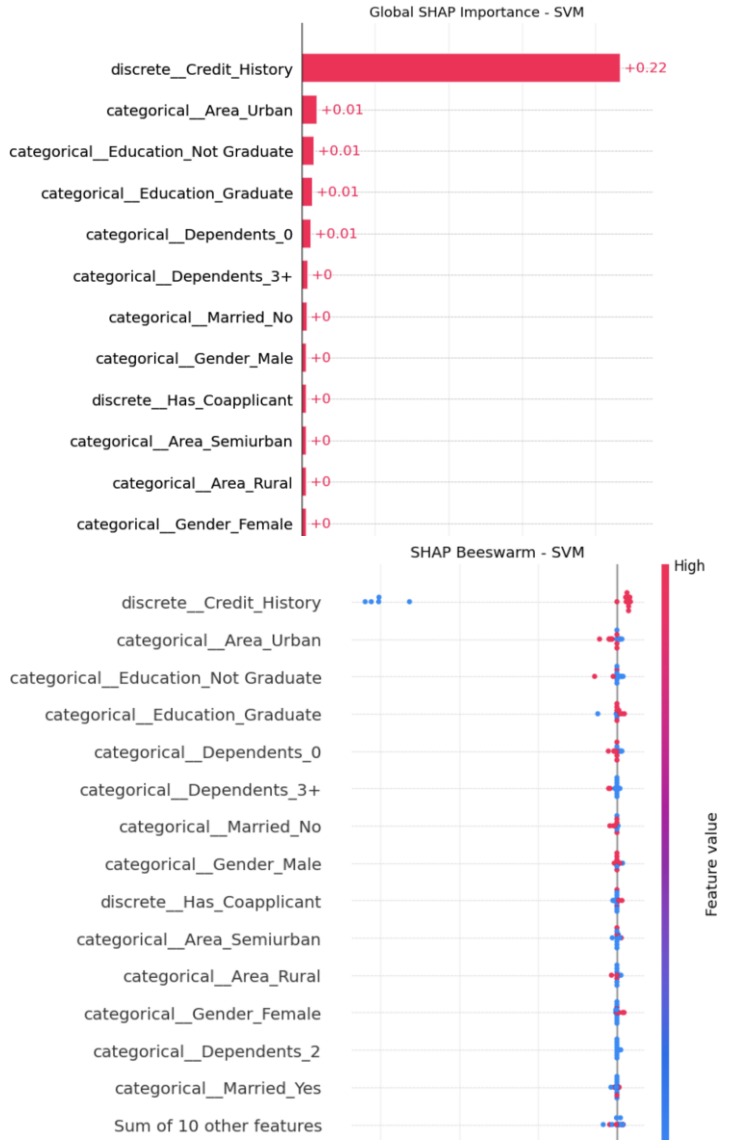
شکل ۱۵. اهمیت جایگشتی ویژگی‌های خام بر پایه کاهش F۱

۳-۱۴. تفسیر جهانی با SHAP

برای مدل SVM از Kernel SHAP استفاده شد. پس از مهندسی ویژگی و کدگذاری، ۲۴ ویژگی تبدیل‌شده ایجاد شد. برای کنترل هزینه‌ی محاسباتی، ۲۵ نمونه‌ی پس‌زمینه و ۱۵ نمونه از مجموعه‌ی نگه‌داشته‌شده با ۶۰ ارزیابی تقریبی استفاده شدند. جدول ۱۸ اهمیت تجمیع‌شده‌ی ویژگی‌های اصلی را نشان می‌دهد. سابقه‌ی اعتباری با فاصله‌ی زیاد رتبه‌ی نخست را دارد؛ منطقه، تحصیلات و افراد تحت تکفل در رتبه‌های بعدی قرار گرفتند.

جدول ۱۸. مهم‌ترین ویژگی‌ها بر پایه میانگین قدر مطلق SHAP

ویژگی	میانگین قدر مطلق SHAP
Credit_History	۰/۲۱۶۸
Area	۰/۰۱۶۸
Education	۰/۰۱۶۰
Dependents	۰/۰۱۵۱
Gender	۰/۰۰۶۳
Married	۰/۰۰۶۰
Has_Coapplicant	۰/۰۰۳۱
Self_Employed	۰/۰۰۲۷



شکل ۱۶. تفسیر جهانی مدل منتخب با SHAP

۳-۱۵. تفسیر محلی تصمیم‌ها

برای پرهیز از انتخاب گزینشی نمونه‌ها، سه نمونه شامل یک پیش‌بینی صحیح با اطمینان بالا، یک مثبت کاذب و یک منفی کاذب بررسی شدند. احتمال تعلق به کلاس تأیید که مدل برای این سه نمونه برآورد کرد، به‌ترتیب ۰/۰۸۶۳، ۰/۸۲۰۱ و ۰/۰۸۸۹ بود. همان‌طور که در شکل ۱۷ مشاهده می‌شود، سابقه‌ی اعتباری[۱۶] مهم‌ترین عامل در افزایش یا کاهش احتمال پیش‌بینی‌شده توسط مدل است. بررسی نمونه‌ی مثبت کاذب از اهمیت ویژه‌ای برخوردار است، زیرا نشان می‌دهد مدل تحت تأثیر سابقه‌ی اعتباری مطلوب، این درخواست را در کلاس تأیید قرار داده است، در حالی که برچسب واقعی آن رد بوده است. این موضوع بیانگر آن است که اتکای زیاد مدل به این ویژگی، در برخی موارد می‌تواند به پیش‌بینی نادرست منجر شود.

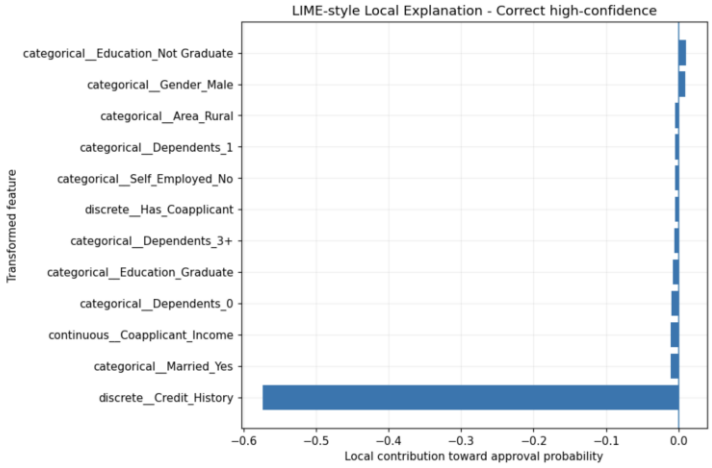
[۱۶] Credit history



شکل ۱۷. دو توضیح محلی SHAP

۳-۱۶. توضیح محلی LIME-style

برای هرنمونه، ۲۰۰۰ نمونه محلی با جایگزینی تصادفی ویژگی‌ها بر اساس داده‌های آموزش تولید شد و سپس یک مدل رگرسیون ریج وزن‌دار به‌عنوان مدل جانشین برازش داده شد. ضریب تعیین این مدل برای نمونه‌ی صحیح و منفی کاذب به‌ترتیب ۰٫۷۷۱۲ و ۰٫۷۵۶۶ بود که نشان می‌دهد مدل جانشین توانسته است رفتار محلی مدل اصلی را با دقت قابل قبولی تقریب بزند. در مقابل، برای نمونه‌ی مثبت کاذب مقدار R^2 تنها ۰٫۱۰۰۳ به دست آمد. بنابراین، توضیح LIME-style این نمونه از وفاداری پایینی برخوردار است و نباید مبنای تفسیر قطعی قرار گیرد.



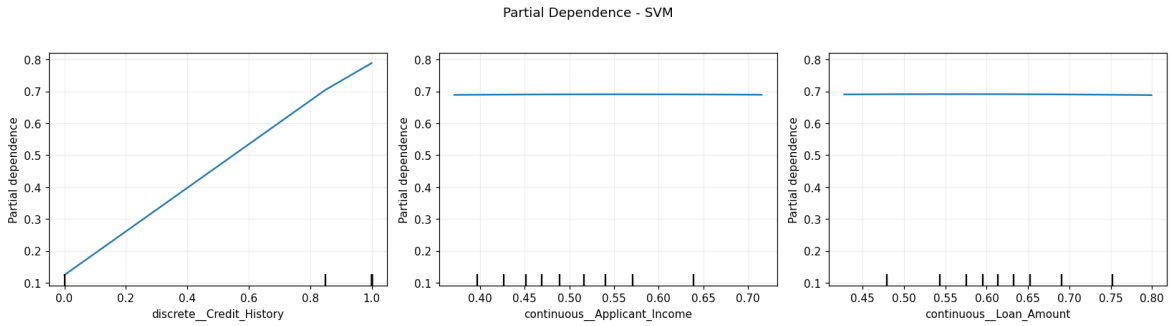
شکل ۱۸ LIME.

جدول ۱۹ .توضیحات محلی LIME-style

نمونه	احتمال مدل اصلی	احتمال مدل جانشین	R^2محلی وزن‌دار
صحیح با اطمینان بالا	۰/۰۸۶۳	۰/۰۸۷۷	۰/۷۷۱۲
مثبت کاذب	۰/۸۲۰۱	۰/۷۹۷۳	۰/۱۰۰۳
منفی کاذب	۰/۰۸۸۹	۰/۰۷۸۰	۰/۷۵۶۶

۳-۱۷. وابستگی جزئی

نمودارهای وابستگی جزئی در شکل ۱۹ اثر متوسط سابقه‌ی اعتباری، درآمد متقاضی و مبلغ وام را پس از کنترل سایر ویژگی‌ها نمایش می‌دهند. منحنی سابقه‌ی اعتباری جهش روشن در احتمال تأیید دارد. اثر دو متغیر مالی ضعیف‌تر و غیرخطی است. به دلیل اندازه‌ی کوچک داده و هم‌بستگی میان درآمد و مبلغ وام، این نمودارها باید به‌عنوان توصیف رفتار مدل و نه رابطه‌ی علّی تفسیر شوند.

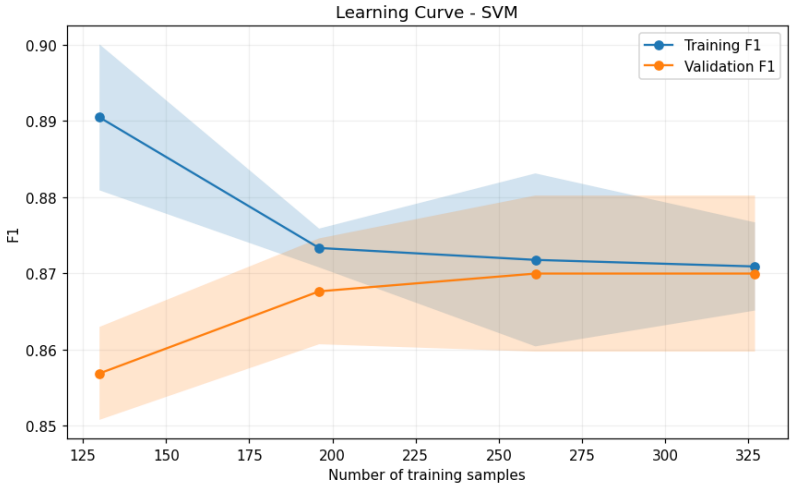


شکل ۱۹. نمودار وابستگی جزئی ویژگی‌های منتخب در مدل SVM

۳-۱۸. منحنی یادگیری و بیش‌برازش

در منحنی یادگیری شکل ۱۳، با افزایش اندازه‌ی آموزش از ۱۳۰ به ۳۲۷ نمونه، میانگین F1 آموزش از ۰/۸۹۰۵ به ۰/۸۷۰۹ و میانگین اعتبارسنجی از ۰/۸۵۶۹ به ۰/۸۷۰۰ نزدیک شد. شکاف نهایی بسیار کوچک

است و نشانه‌ای از بیش‌برازش شدید دیده نمی‌شود. همگرایی دو منحنی در سطح حدود ۰/۸۷ نشان می‌دهد افزایش داده‌ی با کیفیت می‌تواند برای بهبود بیشتر مفیدتر از افزایش پیچیدگی مدل باشد.



شکل ۲۰. منحنی یادگیری مدل منتخب بر پایه ۱۴

۳-۱۹. تحلیل عملکرد در زیرگروه‌ها

جدول ۲۰ اختلاف عملکرد در زیرگروه‌ها را نشان می‌دهد. عملکرد در منطقه‌ی نیمه‌شهری بسیار بهتر از منطقه‌ی روستایی بود. در گروه روستایی دقت متوازن فقط ۰/۵۶۰۶ و F1 برابر ۰/۷۹۲۵ بود، در حالی که این مقادیر در نیمه‌شهری به ۰/۹۲۳۱ و ۰/۹۷۳۰ رسید. این اختلاف ممکن است از اندازه نمونه، ترکیب ویژگی‌ها یا سیاست تاریخی تأیید ناشی شود. تحلیل جنسیت و تحصیلات نیز تفاوت‌هایی نشان داد، اما اندازه‌ی زیرگروه‌ها برای نتیجه‌گیری درباره عدالت الگوریتمی کافی نیست.

جدول ۲۰. عملکرد مدل در زیرگروه‌های دارای حداقل ۱۰ نمونه

ویژگی	گروه	تعداد	دقت	دقت متوازن	فراخوانی	F1
جنسیت	مرد	۹۶	۰/۸۵۴۲	۰/۷۵۴۹	۰/۹۷۱۴	۰/۹۰۶۷
جنسیت	زن	۲۵	۰/۸۴۰۰	۰/۸۱۸۲	۱/۰۰۰۰	۰/۸۷۵۰
منطقه	روستایی	۳۴	۰/۶۷۶۵	۰/۵۶۰۶	۰/۹۵۴۵	۰/۷۹۲۵
منطقه	نیمه‌شهری	۴۹	۰/۹۵۹۲	۰/۹۲۳۱	۱/۰۰۰۰	۰/۹۷۳۰
منطقه	شهری	۴۰	۰/۸۵۰۰	۰/۷۸۹۲	۰/۹۶۳۰	۰/۸۹۶۶
تحصیلات	فارغ‌التحصیل	۱۰۰	۰/۸۵۰۰	۰/۷۵۱۶	۰/۹۸۵۹	۰/۹۰۳۲
تحصیلات	غیر فارغ‌التحصیل	۲۳	۰/۸۲۶۱	۰/۷۹۷۶	۰/۹۲۸۶	۰/۸۶۶۷

۳-۲۰. بحث و برداشت از نتایج

مقایسه‌ی مدل‌ها چند نکته‌ی مهم را آشکار کرد. نخست اینکه، بهترین عملکرد روی یک تقسیم ثابت از داده‌ها لزوماً به معنای بهترین انتخاب نهایی نیست. اگرچه گرادیان بوستینگ روی مجموعه‌ی نگه‌داشته‌شده مقدار F1 بالاتری به دست آورد، اختلاف آن با ماشین بردار پشتیبان در اعتبارسنجی متقابل تکرارشونده بسیار ناچیز بود و SVM میانگین F1 کمی بالاتری داشت. ازاین‌رو، انتخاب مدل نهایی بر اساس عملکرد پایدارتر در تقسیم‌بندی‌های مختلف داده انجام شد، نه صرفاً نتیجه‌ی حاصل از یک بار اجرای مدل.

نکته‌ی دوم به مسئله‌ی عدم تعادل کلاس‌ها مربوط می‌شود. انتظار می‌رفت روش‌هایی مانند SMOTE یا وزن‌دهی کلاس‌ها عملکرد مدل را بهبود دهند، اما در عمل استفاده از آن‌ها باعث کاهش F1 شد. این نتیجه نشان می‌دهد که به‌کارگیری روش‌های متعادل‌سازی نباید به‌صورت خودکار انجام شود، بلکه لازم است تأثیر هرروش بر داده و معیار اصلی مسئله به‌طور جداگانه بررسی شود.

نکته‌ی سوم، وابستگی زیاد مدل به ویژگی سابقه‌ی اعتباری بود. این متغیر در تحلیل اکتشافی، اهمیت جایگشتی و تحلیل SHAP بیشترین اهمیت را داشت. همچنین، همه‌ی نمونه‌های مثبت کاذب دارای سابقه‌ی اعتباری مطلوب بودند. این یافته نشان می‌دهد که مدل در برخی موارد ممکن است بیش از حد به این ویژگی متکی باشد و سایر اطلاعات متقاضی را کمتر در نظر بگیرد. افزون بر این، تفاوت عملکرد میان مناطق، به‌ویژه عملکرد ضعیف‌تر در گروه روستایی، نشان می‌دهد که ارزیابی کلی مدل به‌تنهایی کافی نیست و عملکرد آن باید در زیرگروه‌های مختلف نیز بررسی شود.

.

۳-۲۱. آموزش نهایی و پیش‌بینی داده آزمون

پس از انتخاب مدل نهایی، پایپ‌لاین SVM با استفاده از کل ۶۱۴ نمونه برچسب‌دار مجدداً آموزش داده شد. سپس، آستانه‌ی تصمیم با استفاده از پیش‌بینی‌های خارج از نمونه روی کل داده‌های آموزشی تعیین شد که مقدار بهینه‌ی آن ۰٫۲۶۵ به دست آمد. مدل در نهایت برای ۳۶۷ نمونه مجموعه‌ی آزمون پیش‌بینی تولید کرد که از این میان ۳۰۸ درخواست (۸۳٫۹۲ درصد) به‌عنوان تأیید و ۵۹ درخواست (۱۶٫۰۸ درصد) به‌عنوان رد طبقه‌بندی شدند.

تفاوت آستانه‌ی نهایی ۰٫۲۶۵ با آستانه‌ی ۰٫۵۴۵ که در تقسیم اولیه داده‌ها به دست آمده بود، نشان می‌دهد برآورد آستانه تصمیم و امتیازهای پیش‌بینی SVM در مجموعه‌داده‌های کوچک می‌تواند نسبت به نحوه تقسیم داده‌ها حساس باشد. ازاین‌رو، در کاربردهای عملی، استفاده از کالیبراسیون احتمال و اعتبارسنجی روی داده‌های مستقل (اعتبارسنجی بیرونی) می‌تواند به افزایش قابلیت اعتماد مدل کمک کند.

از آنجا که مجموعه‌ی آزمون فاقد برچسب واقعی بود، امکان محاسبه‌ی معیارهای ارزیابی مانندAccuracy ، ماتریس اغتشاش، تعداد مثبت‌های کاذب و منفی‌های کاذب برای این داده‌ها وجود نداشت. در نهایت، خروجی پیش‌بینی‌ها در دو فایل مجزا، شامل فایل برچسب‌های پیش‌بینی‌شده و فایل برچسب‌ها به همراه احتمال تعلق به کلاس تأیید، ذخیره شد.

۴. نتیجه‌گیری

در این پروژه، تمام مراحل یک مسئله‌ی طبقه‌بندی، از شناخت داده تا تفسیر مدل، به‌صورت نظام‌مند انجام شد. در تحلیل اولیه مشخص شد که سابقه‌ی اعتباری مهم‌ترین ارتباط را با وضعیت درخواست وام دارد. نرخ تأیید برای متقاضیان دارای سابقه‌ی اعتباری مطلوب ۷۹٫۵۸ درصد و برای متقاضیان دارای سابقه‌ی نامطلوب تنها ۷٫۸۷ درصد بود. همچنین، ویژگی‌های منطقه‌ی محل سکونت و سطح تحصیلات نیز با وضعیت درخواست ارتباط داشتند، هرچند اثر آن‌ها به‌مراتب کمتر از سابقه‌ی اعتباری بود.

در مرحله پیش‌پردازش، سه روش جای‌گذاری مقادیر گمشده، چهار روش مقیاس‌بندی، چهار سناریوی مدیریت چولگی و چهار روش برخورد با عدم تعادل کلاس‌ها با یکدیگر مقایسه شدند. بر اساس معیار F1، جای‌گذاری میانگین، مقیاس‌بندی حداقل–حداکثر و تبدیل لگاریتمی به‌عنوان بهترین گزینه‌ها انتخاب شدند. همچنین، استفاده از عدم نمونه‌برداری عملکرد بهتری نسبت به SMOTE، نمونه‌برداری تصادفی و وزن‌دهی کلاس‌ها داشت. این نتیجه نشان داد که استفاده از روش‌های متعادل‌سازی باید بر اساس نتایج اعتبارسنجی انجام شود و نه صرفاً به دلیل نامتوازن بودن کلاس‌ها.

در ادامه، شش مدل مختلف آموزش داده و ابرپارامترهای آن‌ها تنظیم شدند. اگرچه گرادیان بوستینگ روی مجموعه نگه‌داشته‌شده بالاترین مقدار F1 را به دست آورد، اختلاف آن با ماشین بردار پشتیبان در اعتبارسنجی متقابل تکرارشونده بسیار ناچیز بود. از آنجا که معیار انتخاب مدل از ابتدا میانگین F1 در اعتبارسنجی متقابل تکرارشونده تعیین شده بود، ماشین بردار پشتیبان با میانگین F1 برابر ۰٫۸۷۰۷ و انحراف معیار ۰٫۰۲۱۳ به‌عنوان مدل نهایی انتخاب شد. این مدل با آستانه‌ی ۰٫۵ روی مجموعه‌ی نگه‌داشته‌شده به Accuracy برابر ۰٫۸۵۳۷، Recall برابر ۰٫۹۸۸۲ و F1 برابر ۰٫۹۰۳۲ دست یافت. مقدار بالای Recall مهم‌ترین نقطه‌ی قوت مدل بود، اما وجود ۱۷ مثبت کاذب نیز نشان داد که مدل همچنان در تشخیص بخشی از درخواست‌های ردشده دچار خطا می‌شود.

نتایج تحلیل‌های تفسیرپذیری نیز با یافته‌های تحلیل اکتشافی هم‌خوانی داشت. سابقه‌ی اعتباری در هردو روش اهمیت جایگشتی و SHAP بیشترین اهمیت را به خود اختصاص داد. همچنین، بررسی خطاهای مدل نشان داد که همه‌ی نمونه‌های مثبت کاذب دارای سابقه اعتباری مطلوب بودند. این موضوع نشان می‌دهد که مدل در برخی موارد بیش از اندازه به این ویژگی متکی بوده و سایر ویژگی‌ها را کمتر در تصمیم‌گیری دخالت داده است. علاوه بر این، عملکرد ضعیف‌تر مدل در منطقه روستایی و وفاداری پایین توضیح LIME-style برای نمونه‌ی مثبت کاذب نشان داد که ارزیابی عملکرد مدل نباید تنها به معیارهای کلی محدود شود، بلکه بررسی زیرگروه‌ها و کیفیت توضیح‌های محلی نیز ضروری است.

مهم‌ترین محدودیت‌های این پروژه شامل اندازه کوچک مجموعه‌داده، نبود برچسب واقعی برای داده‌های آزمون، مشخص نبودن روش نمونه‌گیری داده‌ها و استفاده از وضعیت تاریخی تأیید درخواست به‌جای نکول واقعی وام بود. همچنین، اختلاف آستانه بهینه به‌دست‌آمده در تقسیم اولیه‌ی داده‌ها با آستانه‌ی محاسبه‌شده روی کل داده‌های آموزشی نشان داد که برآورد احتمال‌های مدل هنوز به کالیبراسیون و ارزیابی روی داده‌های مستقل نیاز دارد. برای ادامه‌ی این پژوهش، استفاده از داده‌های بزرگ‌تر و زمان‌مند، اعتبارسنجی بیرونی،

کالیبراسیون احتمال، معیارهای هزینه‌محور و بررسی دقیق‌تر عدالت مدل در زیرگروه‌های مختلف پیشنهاد می‌شود.

۵. فهرست مراجع

[۱] D. J. Hand and W. E. Henley, “Statistical Classification Methods in Consumer Credit Scoring: A Review,” *J. R. Stat. Soc. Ser. A Stat. Soc.*, vol. ۱۶۰, no. ۳, pp. ۵۲۳–۵۴۱, Sep. ۱۹۹۷, doi: ۱۰.۱۱۱۱/j.۱۴۶۷-۹۸۵X.۱۹۹۷.۰۰۰۷۸.x.

[۲] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research,” *Eur. J. Oper. Res.*, vol. ۲۴۷, no. ۱, pp. ۱۲۴–۱۳۶, Nov. ۲۰۱۵, doi: ۱۰.۱۰۱۶/j.ejor.۲۰۱۵.۰۵.۰۳۰.

[۳] C.-L. Huang, M.-C. Chen, and C.-J. Wang, “Credit scoring with a data mining approach based on support vector machines,” *Expert Syst. Appl.*, vol. ۳۳, no. ۴, pp. ۸۴۷–۸۵۶, Nov. ۲۰۰۷, doi: ۱۰.۱۰۱۶/j.eswa.۲۰۰۶.۰۷.۰۰۷.

[۴] A. E. Khandani, A. J. Kim, and A. W. Lo, “Consumer credit-risk models via machine-learning algorithms,” *J. Bank. Financ.*, vol. ۳۴, no. ۱۱, pp. ۲۷۶۷–۲۷۸۷, Nov. ۲۰۱۰, doi: ۱۰.۱۰۱۶/j.jbankfin.۲۰۱۰.۰۶.۰۰۱.

[۵] C. Cortes and V. Vapnik, “Support-vector networks,” *Mach. Learn.*, vol. ۲۰, no. ۳, pp. ۲۷۳–۲۹۷, Sep. ۱۹۹۵, doi: ۱۰.۱۰۰۷/BF۰۰۹۹۴۰۱۸.

[۶] L. Breiman, “Random Forests,” *Mach. Learn.*, vol. ۴۵, no. ۱, pp. ۵–۳۲, Oct. ۲۰۰۱, doi: ۱۰.۱۰۲۳/A:۱۰۱۰۹۳۳۴۰۴۳۲۴.

[۷] J. H. Friedman, “Greedy function approximation: A gradient boosting machine.,” *The Annals of Statistics*, vol. ۲۹, no. ۵, Oct. ۲۰۰۱, doi: ۱۰.۱۲۱۴/aos/۱۰۱۳۲۰۳۴۵۱.

[۸] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. ۱۶, pp. ۳۲۱–۳۵۷, Jun. ۲۰۰۲, doi: ۱۰.۱۶۱۳/jair.۹۵۳.

[۹] M. T. Ribeiro, S. Singh, and C. Guestrin, “‘Why Should I Trust You?,’” in *Proceedings of the ۲۲nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, New York, NY, USA: ACM, Aug. ۲۰۱۶, pp. ۱۱۳۵–۱۱۴۴. doi: ۱۰.۱۱۴۵/۲۹۳۹۶۷۲.۲۹۳۹۷۷۸.